POLYTECHNIQUE MONTRÉAL

LE GÉNIE EN PREMIÈRE CLASSE

Review on 5G New Radio

ELE6709 Course Project

Winter 2021

Lecturer: Prof. Jean-François Frigon

Authors

Mansour Naslcheraghi (1965148)

Claudio Alkazzi (2096201)

Alexandre Sibué (1792034)

Maha Abdelkhalek (1938475)

CONTENTS

I Introduction 6

II Le réseau d'accès radio 5G (RAN) 7

II-A Réseau d'accès radio Cloud (C-RAN) 7

II-B Réseau d'accès radio virtuel V-RAN: L'évolution du C-RAN 11

II-C Open-RAN (O-RAN) 13

III Les options de déploiement du réseau 5G 15

III-A Standalone 15

III-B Non-Standalone 16

IV Les exigences de faible latence et de fiabilité ultra-élevées 16

IV-A Exigence de faible latence 17

IV-B Exigences de fiabilité ultra-élevées 17

V Faible latence: Solutions de la couche physique 18

V-A Structure du paquet 19

V-B Structure de trame 20

VI Accès multiple non orthogonal (NOMA) 21

VI-A Concept du NOMA 23

VI-B Comparaison avec OMA 24

VI-C Avantages et limitations de NOMA 25

VII Radio Resource Management in 5G NR 26

VII-A Numerology and frame Structure in 5G NR 27

VII-B Slot Format and Time Duration 29

VIII Which Numerology and When: Resource Allocation in 5G NR 30

VIII-A Time and Frequency Domain Resource Allocation in 5G NR 33

VIII-B Some Challenges and Ongoing Efforts to Resolve Them 33

VIII-B1 Interference Pattern Derivation 34

VIII-B2 Filtering & Guard Band Design 34
VIII-B3 Scheduling 35

IX Concluding Remarks and Potential Open Research Directions 36

X Massive MIMO et connexion D2D 38
X-A Massive MIMO 38
X-B Connexion D2D 39

XI Beamforming: Overview and Benefits 43
XI-A Enhanced Energy Efficiency 43
XI-B Improved Spectral Efficiency 45
XI-C Increased Security 45

XII Classification of Beamforming Techniques 46
XII-A Analog vs. Digital vs. Hybrid 46
XII-A1 Analog Beamforming 46
XII-A2 Digital Beamforming 47
XII-A3 Hybrid Beamforming 48
XII-B Switched vs. Adaptive 49
XII-B1 Switched Beamforming 49
XII-B2 Adaptive Beamforming 49

XIII Sample Beam Management Algorithm 50

XIV Conclusion 51

References 52

LIST OF FIGURES

1 Disposition cellulaire hétérogène[1]. 8

2 Evolution de C-RAN vers le O-RAN[2]. 9

3 Architecture C-RAN, où les RRH et BBU sont séparés, cependant, tous les RRHs sont connectés à une unité de traitement de bande de base partagée et centralisée dans un groupe BBU virtualisé via le fronthaul[1]. 10

4 La solution C-RAN entièrement centralisé, où toutes les fonctions liées à la couche physique, la couche liaison de données et la couche réseau sont situées dans le BBU[1]. 11

5 La solution C-RAN partiellement centralisée, où les fonctions de la couche physique sont intégrées dans RRH, cependant, les fonctions liées aux couches liaison de données et réseau sont situées dans BBU[1]. 12

6 Comparaison des technologies de virtualisation[2]. 13

7 Architecture O-RAN[2]. 14

8 Vue d'ensemble des options SA et NSA.[3] 16

9 Illustration des composants de latence.[4] 17

10 Strucure du paquet.[4] 19

11 PER de la transmission de paquets courts (12 bits) pour URLLC[4] 20

12 Structure de trame.[4] 21

13 numérologies pour la 5G NR.[4] 22

14 Illustration de la liaison descendante NOMA.[5] 23

15 Comparaison entre NOMA et OMA.[5] 25

16 Sweet spectrum for more than 4 decades. 27

17 Capacity and coverage of different spectrum. 27

18 Bandwidth of RBs for different numerologies. 28

19 Demonstration of (a) Slot-Based subframe and (b) Mini-Slot based subframe. 29

20 Relationship between the duration and and the number of slots within a frame. 30

21 Frame Structure based on different numerologies. 30

22 OFDM numerology design for wide range of carrier frequencies, deployment types, and application latency requirements using regular slots [6]. 31

23 Optimal subcarrier spacing frequency versus Doppler effect [7] 32

24 Adaptive guardband design in [8] 34
25 UL/DL allocations and slot formats in 5G NR; table is abstracted from [9]. 36
26 Efficacité énergétique en fonction de l'efficacité spectrale des différents codes [10] 40
27 Vue d'ensemble du système de communication D2D [11] 41
28 Utilisation d'un usager comme relai pour l'antenne [11] 41
29 Type de communication D2D [11] 42
30 Sample radiation pattern after beamforming taken from [12] 44
31 System under study. Shows users, RRHs and Eve 45
32 SINR comparison between UE and Eve 46
33 Analog beamformer at transmitter focusing a beam at a particular angle 47
34 Digital beamforming receiver architecture 48
35 Hybrid beamforming architecture 49
36 Adaptive (a) vs. switched (b) beamforming 49
37 Sample beam management algorithm using beam sweeping 51

LIST OF TABLES

I 5G NR Numerology 29

II Sub-6 GHz and mmWave SCS and BW per carrier [13] 29

III Service requirements and their effects numerology parameters [14]. 32

IV User requirements and their effects numerology parameters [14]. 32

V Total energy efficiency for an optimal number of antennas M 44

I. Introduction

Afin de diversifier les nouveaux services et applications, l'Union Internationale de Télécommunications(ITU) a classifié les service 5G en trois catégories:

a) Ultra-reliable and low latency communication (URLLC): C'est une catégorie de services sensibles à la latence tels que la conduite autonome, l'internet tactile et la télécommande[15]. Étant donné que la réaction humaine est de l'ordre de plusieurs dizaines de millisecondes, les applications critiques nécessitent un temps de transmission des paquets dans le même ordre de dizaines de millisecondes[16]. Par conséquent; des changements devraient être apportés à la liaison sans fil et au réseau dorsal (backbone). Dans la liaison sans fil, il faut réduire la surcharge due à la signalisation. Par conséquent, de nombreuses parties de la couche physique doivent être repensées. Des nouvelles approches proposées dans la 5G qui traitent ces défis et qui vont être présentées dans le reste de ce rapport. Le découpage de réseau virtuel et le réseau défini par logiciel (SDN) peuvent être utilisés pour construire la connexion privée au service URLLC dédié[15].

b) Massive machine-type communication (mMTC): mMTC est une catégorie de service pour prendre en charge l'accès à un grand nombre d'appareils de type machine. On peut citer la détection, l'étiquetage, le comptage et la surveillance parmi les services qui nécessitent une densité de connexion élevée et une meilleure efficacité énergétique[17]. Des approches ont été proposées offrant une faible consommation d'énergie, un faible coût d'exploitation et une couverture améliorée comme SigFox et LoRa[15]. Ces approches prennent en charge les communications de type machine telles que l'Internet des objets à bande étroite (NB-IoT). Cependant, dans des scénarios où le nombre d'appareils est plus grand que les ressources utilisées lors de la transmission, il est nécessaire de changer le pricipe de transmission orthogonale. Dernièrement, des nouvelles approches utilisent une séquence d'étalement non orthogonale ou un entrelacement spécifique à l'utilisateur pour offrir un accès à plus d'utilisateurs simultanément[17].

c) Enhanced mobile broadband (eMBB): Cette catégorie est utilisée pour les services liés à des exigences en terme de bande passante telles que la haute résolution des vidéos streaming, la réalité virtuelle et la réalité augmentée. Le défi principal est donc d'améliorer le débit. Pour cette raison, des nouvelles technologies sont introduites à la couche physique telles que la modulation d'ordre élevé, la densification des cellules via les réseaux hétérogènes, l'agrégation des porteuses et la transmission Entrée-multiples et Sorties-multiples (MIMO).

Pour faire face à ces nouvelles catégories de services, diverses exigences de performances telles qu'une

connectivité massive, une latence plus faible, une fiabilité plus élevée et une meilleure efficacité énergétique ont été récemment introduites. Dans ce rapport on va donc étudier les nouvelles approches et technologies de la 5G qui traitent ces nouveaux défis et qui répondent à ces exigences.

Ce rapport est organisé selon cette structure; on commence par une brève description du réseau d'accès 5G (RAN) expliquant l'évolution du RAN de C-RAN (Cloud-RAN) vers le O-RAN (Open-RAN). La partie suivante est toujours dans le principe architectural de la 5G qui décrit les différentes options de déploiement du réseau 5G. Par la suite, on expliquera les défis liés à la faible latence pour la couche physique ainsi les solutions proposées. Des approches qui traitent les exigences en terme de fiabilité pour la couche liaison (Couche MAC) seront étudiées dans la partie suivante. On va aussi étudier la future technique d'accès multiple non orthogonale (NOMA). La partie qui suit est consacrée pour introduire et expliquer les principaux défis et solutions pour la gestion des ressources dans la nouvelle radio (NR) 5G. On présentera le MIMO massive en expliquant l'utilité de cette technique dans la 5G ainsi la technique de Beamforming. La dernière partie est réservée à quelques remarques finales qui concluent ce travail.

II. Le réseau d'accès radio 5G (RAN)

Dans cette section, on va discuter le concept architectural de l'évolution du RAN dans le 5G.

L'architecture RAN du réseau mobile 5G est plus hétérogène par rapport aux architectures RAN des anciens réseaux LTE/LTE-A. Comme le montre la figure 1, divers types de petites cellules sont déployés pour répondre aux demandes de capacité et de couverture des futurs réseaux 5G. Dans une disposition cellulaire hétérogène, le niveau macrocellules est utilisé pour fournir une large couverture et une mobilité transparente sur de grandes zones géographiques, tandis que de petites cellules sont déployées pour améliorer la couverture et augmenter la capacité en déplaçant les noeuds de calcul et de communication à proximité des utilisateurs finaux.

La figure 2 illustre la relation et l'évolution du concept C-RAN et de ses dérivés V-RAN et O-RAN.

A. Réseau d'accès radio Cloud (C-RAN)

Toutes les fonctions de traitement radio et bande de base de 2G RAN sont intégrées dans la station de base (SB). En revanche, avec le déploiement du D-RAN (Réseau d'accès distribué) dans les réseaux mobiles 3G et 4G, ces fonctions sont divisées en deux nœuds distincts; unité radio distante (RRH: Remote Radio Head) et Unité de bande de base (BBU: BaseBand Unit). Avec les diverses exigences de qualité de service et la quantité de données utilisateur qui a augmenté, les opérateurs de réseau sont

Fig. 1: Disposition cellulaire hétérogène[1].

contraints de répondre à ces exigences par la centralisation et la cloudification des BBUs et de leurs RRHs correspondants. Ce nouveau RAN centralisé et cloudifié est connu sous le nom de C-RAN[18].

Comme le montre la figure 3, le concept principal du C-RAN est de séparer tous les BBUs de leurs RRHs correspondants et de les regrouper dans un groupe BBU centralisé, cloudifié, partagé et virtualisé. Chaque RRH est connecté via une liaison ”fronthaul” à son groupe BBU correspondant. Chaque groupe BBU est capable de prendre en charge jusqu’à des dizaines de RRHs et est connecté via une liaison ”backhaul” avec le réseau central. L’architecture C-RAN diminue les CAPEX et OPEX des opérateurs de réseaux mobiles (MNO), réduit la consommation d’énergie, augmente l’évolutivité du réseau, simplifie la gestion et la maintenance du réseau, améliore l’efficacité spectrale et le débit du réseau, et facilite l’équilibrage de charge.

Le C-RAN intègre le cloud computing dans l’architecture RAN de la 5G. Il repose initialement sur deux principes principaux: la centralisation et la virtualisation du traitement en bande de base. La centralisation vise à optimiser les performances du réseau, à réduire la consommation d’énergie et à augmenter l’efficacité

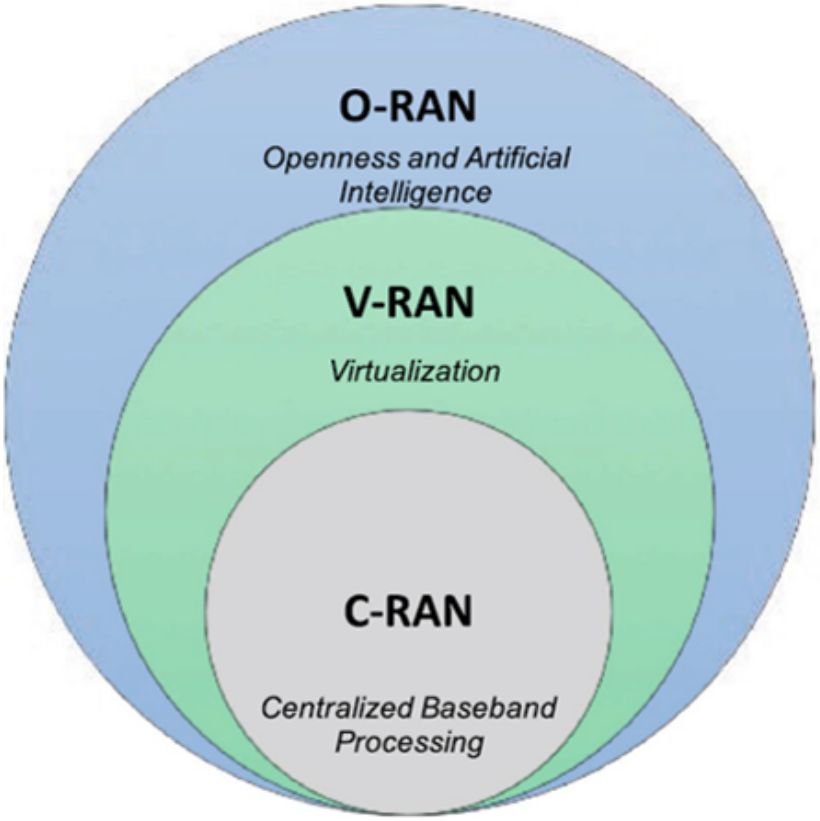

Fig. 2: Evolution de C-RAN vers le O-RAN[2].

spectrale. Parallèlement, la virtualisation du traitement en bande de base vise à diminuer les CAPEX et les OPEX des réseaux mobiles 5G[1].

Le C-RAN peut être classé en deux types selon la répartition des fonctions entre RRH et BBU:

- C-RAN entièrement centralisé;
- C-RAN partiellement centralisé.

a) C-RAN entièrement centralisé: Dans un C-RAN entièrement centralisé, toutes les fonctions liées à la couche physique (échantillonnage, modulation, mappage de blocs de ressources, mappage d'antenne, quantification, etc.), la couche liaison de données (comme le contrôle d'accès au support de transport) et la couche réseau (comme le contrôle des ressources radio) sont situés dans le BBU (comme indiqué sur la Fig. 4). Certaines clés apportées par ce type de C-RAN au réseau mobile 5G sont l'expansion facile de la couverture du réseau, la mise à niveau facile de la capacité du réseau, la prise en charge du fonctionnement multi-standard, l'amélioration du partage des ressources réseau et la prise en charge du traitement du signal collaboratif multicellulaire. Malgré tous ces avantages, le C-RAN entièrement centralisé est confronté à deux défis majeurs: les besoins en bande passante élevée et la transmission du signal en bande de base entre RRH et BBU. Une solution C-RAN entièrement centralisée associée à des

plates-formes ouvertes facilitent le développement et la mise en œuvre de SDR (Software Defined Radio). Cela conduit à une mise à niveau de l'interface radio par le biais d'un logiciel, ce qui permet en outre de mettre à niveau l'architecture RAN de manière plus pratique et de prendre en charge un fonctionnement multi-standard.

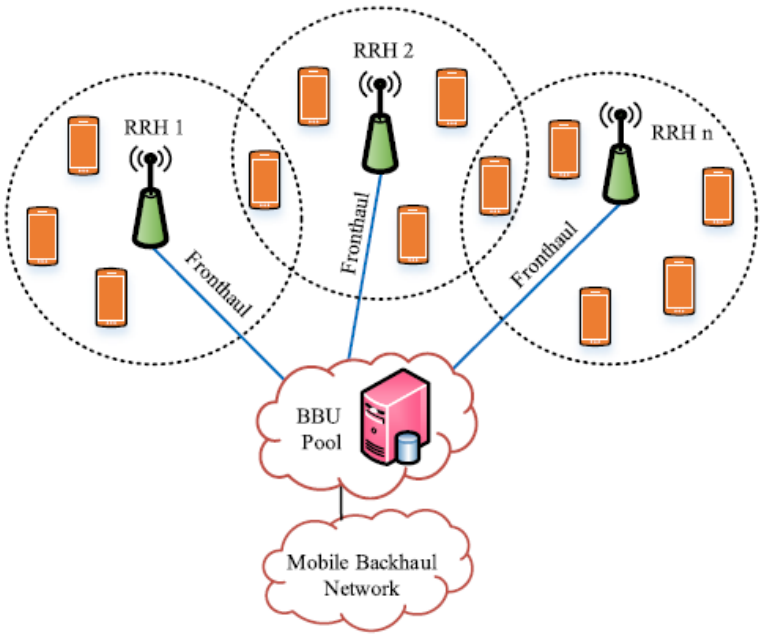

Fig. 3: Architecture C-RAN, où les RRH et BBU sont séparés, cependant, tous les RRHs sont connectés à une unité de traitement de bande de base partagée et centralisée dans un groupe BBU virtualisé via le fronthaul[1].

b) C-RAN partiellement centralisé: Dans un C-RAN partiellement centralisé, les fonctions de traitement radio et bande de base sont intégrées dans le RRH, tandis que toutes les fonctions liées aux couches hautes sont intégrées dans la BBU (comme le montre la figure 5). Cela signifie spécifiquement que les fonctions liées à la couche physique sont situées dans RRH, tandis que les fonctions liées à la couche liaison des données et couche réseau sont situées dans BBU. Ce type de C-RAN nécessite une faible largeur de bande de transmission entre RRH et BBU, car le traitement de la bande de base est décalé de la BBU vers la RRH. Cependant, cela entraîne également certains défis, tels qu'une faible flexibilité dans les mises à niveau du réseau et une moindre commodité pour le traitement du signal collaboratif multicellulaire.

Les deux types C-RAN ont été étudiés et développés à partir de diverses perspectives visant à répondre aux exigences de la 5G. Le déploiement de l'un ou l'autre dépend des caractéristiques du réseau. Dans les deux cas, si le fournisseur de services souhaite étendre la couverture du réseau ou diviser la cellule

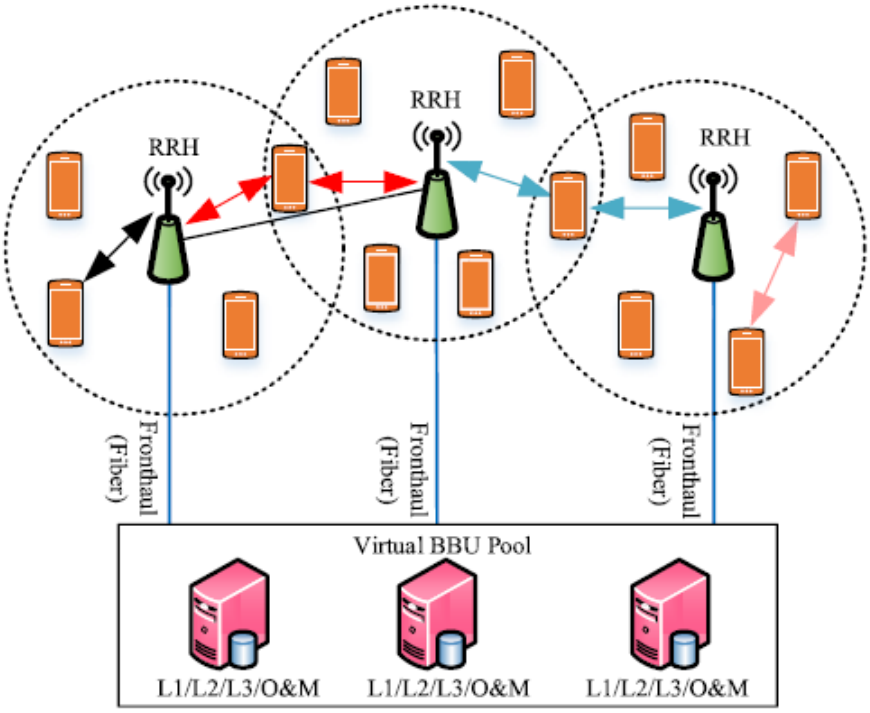

Fig. 4: La solution C-RAN entièrement centralisé, où toutes les fonctions liées à la couche physique, la couche liaison de données et la couche réseau sont situées dans le BBU[1].

afin d'améliorer la capacité, il sera facile de déployer de nouveaux RRH et de les connecter ensuite au groupe BBU. Au contraire, si le fournisseur de services constate une augmentation de la charge du réseau, il lui suffira de mettre à niveau le matériel du groupe BBU afin d'augmenter la capacité de traitement. Il est intéressant de noter qu'avec le déploiement de C-RAN, le couplage statique entre RRH et BBU est desserré. Le RRH n'est plus connecté à un BBU physique dédié. Au lieu de cela, chaque RRH est connecté à une station de base virtuelle située dans le groupe BBU via une technologie de virtualisation en temps réel.

B. Réseau d'accès radio virtuel V-RAN: L'évolution du C-RAN

La virtualisation facilite la création des instances logiquement isolées sur du matériel physique abstrait, qui peuvent être partagées de manière dynamique, efficace et flexible. La virtualisation est utilisée depuis de nombreuses années dans le domaine du stockage de données et du cloud computing[2]. La virtualisation joue un rôle crucial pour les déploiements pratiques du concept C-RAN. Contrairement à C-RAN, l'architecture V-RAN favorise un contrôle flexible, un faible coût, une utilisation efficace des ressources et des applications diversifiées, et peut résoudre de nombreux problèmes liés au déploiement

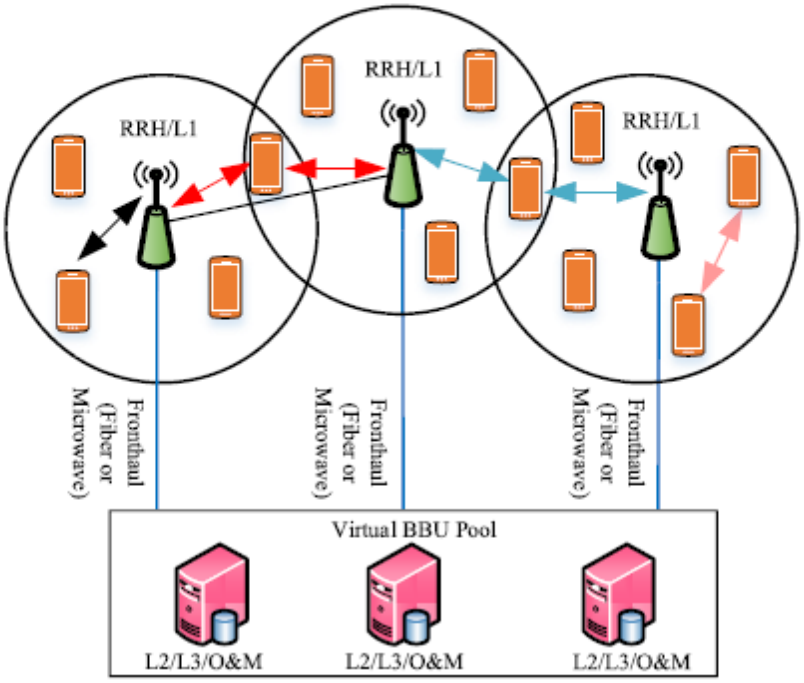

Fig. 5: La solution C-RAN partiellement centralisée, où les fonctions de la couche physique sont intégrées dans RRH, cependant, les fonctions liées aux couches liaison de données et réseau sont situées dans BBU[1].

C-RAN. L'approche, appelée RAN virtuel, c'est-à-dire V-RAN, favorise le découplage des fonctionnalités logicielles et matérielles. En raison du découplage matériel/logiciel du V-RAN, de sa flexibilité, de son évolutivité et de sa nature centralisée inhérente, il peut faciliter une large pléthore de services futurs, tels que l'accès massif aux machines, la criticité de la mission, l'Internet tactile, etc. V-RAN exploite les ressources sans fil/radio et BBU à partager par de nombreux RRHs, en fonction des conditions de trafic sous-jacentes. Cela minimise les coûts d'exploitation et d'investissement lors de l'exécution du système sans fil et favorise une meilleure efficacité énergétique [19]–[21]. Il encourage également les innovations et encourage les nouveaux acteurs commerciaux à pénétrer les marchés à moindre coût [22]. La virtualisation et l'infrastructure cloud pour les applications informatiques ont été déjà bien étudiées et développées. Cependant, le concept V-RAN pose des exigences complètement différentes sur l'infrastructure cloud. Par exemple, la virtualisation basée sur un hyperviseur et sur un conteneur représente deux technologies de virtualisation fondamentales qui peuvent être appliquées dans V-RAN [23], [24]. Les deux technologies

intègrent différents moyens de virtualisation, d'orchestration et de mise à l'échelle des ressources. Ils sont illustrés dans de nombreux frameworks de virtualisation différents, tels que VMware, OpenStack, Kubernetes, Docker, Hyper-V, etc. La majorité des déploiements ICT existants exploitent les frameworks OpenStack (virtualisation basée sur l'hyperviseur) ou Docker (virtualisation basée sur des conteneurs). La figure 6 présente un résumé sur ces deux technologies de virtualisation et de leur applicabilité.

Virtualization technology	Deployment time	System outage due to reconfiguration	Applicable scenarios
Hypervisor-based	High	Very high	Core network and service layer deployment
Container-based	Negligible to perceptible	Negligible to perceptible	RAN deployments

Fig. 6: Comparaison des technologies de virtualisation[2].

C. Open-RAN (O-RAN)

En s'efforçant de résoudre les problèmes les plus imminents, le V-RAN évolue du concept de C-RAN vers le concept d'Open-RAN (O-RAN) et se concentre sur deux piliers fondamentaux: l'ouverture et l'intelligence. Les interfaces ouvertes sont essentielles pour aider les petits fournisseurs et opérateurs à introduire rapidement de nouveaux services et permettre aux opérateurs d'adapter le réseau en fonction de leurs propres besoins. L'ouverture permet également des déploiements V-RAN multifournisseurs, ce qui se traduit par un écosystème plus compétitif et plus riche. De plus, les conceptions logicielles et matérielles open source peuvent faciliter une innovation et un déploiement commercial plus rapides et plus efficaces, tout en préservant la compatibilité descendante avec les systèmes hérités. Les futurs systèmes sans fil tels que la 5G et au-delà de la 5G deviendront également beaucoup plus complexes, en raison de la densification du réseau et des applications plus riches et plus exigeantes. Par conséquent, les opérateurs et les vendeurs des réseaux mobiles devraient s'auto-organiser. Ils devraient être en mesure de tirer parti des nouvelles technologies, telles que l'apprentissage automatique (ML) et l'intelligence artificielle (AI), afin d'automatiser les fonctions opérationnelles du réseau et de réduire les coûts opérationnels. L'initiative O-RAN découle de trois principes clés:

- Diriger l'industrie vers des interfaces ouvertes et interopérables, la virtualisation RAN et l'intelligence RAN activée par le big data;

- Spécifier les API et les interfaces, orienter les normes pour les adopter le cas échéant, et explorer l'open source le cas échéant;
- Maximisez l'utilisation du matériel standard et du silicium marchand et minimisez le matériel propriétaire.

En se basant sur ces principes clés, l'initiative O-RAN exploite largement des technologies avancées telles que: logiciel défini (SD: Software Defined), contrôleur intelligent RAN activé par l'intelligence artificielle, la virtualisation RAN, les interfaces ouvertes, le matériel de boîte blanche (White box hardware) et les logiciels Open Source.

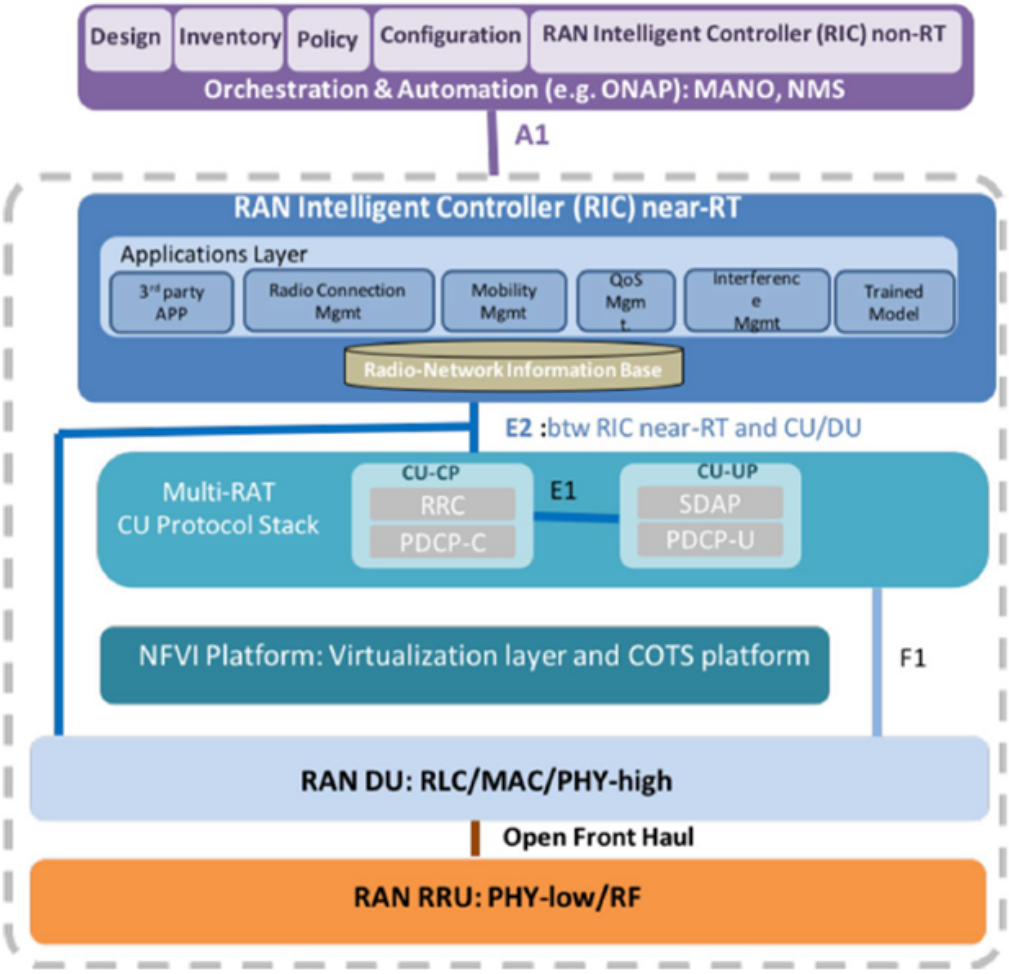

Fig. 7: Architecture O-RAN[2].

La figure 7 illustre l'architecture de O-RAN. Il est conçu pour activer les infrastructures RAN de nouvelle génération. O-RAN est caractérisé par des principes d'intelligence et d'ouverture, l'architecture O-RAN est la base pour favoriser les concepts V-RAN sur du matériel ouvert (open hardware), avec une radiocommande embarquée alimentée par l'intelligence artificielle[2]. L'architecture est basée sur

des interfaces bien définies et normalisées qui permettent un écosystème ouvert et interopérable, qui complètera les normes promues par le 3GPP et d'autres organismes de normalisation de l'industrie. Les principales caractéristiques et modules fonctionnels de l'architecture O-RAN comprennent: la couche RIC non temps réel (non RT), la couche RIC non temps réel (near-RT), la pile de protocoles unité centrale (CU) multi-RAT et plate-forme, de l'unité distribuée (DU) et la définition de la fonction RRH.

III. Les options de déploiement du réseau 5G

Le 3GPP définit à la fois un nouveau cœur de réseau 5G (5GC) ainsi qu'une nouvelle technologie d'accès radio appelée 5G New Radio (NR). Il est possible d'intégrer des éléments de différentes générations dans différentes configurations avec 5G: SA standalone (autonome) et NSA non-standalone (non autonome). Le scénario SA n'utilise qu'une seule technologie d'accès radio (5G NR ou les cellules radio évoluées LTE (Long Term Evolution)) et les réseaux centraux sont exploités seuls. Le scénario NSA combine des cellules radio NR et des cellules radio LTE en utilisant une double connectivité pour fournir un accès radio et le réseau central peut être EPC (Evolved Packet Core) ou 5GC.
Contrairement aux générations précédentes qui exigeaient que l'accès et le réseau central de la même génération soient déployés (par exemple, Evolved Packet Core (EPC) et LTE formaient ensemble un système 4G), avec la 5G, il est possible d'intégrer des éléments de différentes générations dans différentes configurations, à savoir:

- Standalone: utilise une seule technologie d'accès radio;
- Non-Standalone: combine plusieurs technologies d'accès radio.

A. *Standalone*

Dans un scénario standalone, la 5G NR ou les cellules radio LTE évoluées et le réseau central fonctionnent seuls. Cela signifie que les cellules radio NR ou LTE évoluées sont utilisées à la fois pour le plan de contrôle et le plan utilisateur. L'option standalone est une solution simple à gérer pour les opérateurs et peut être déployée en tant que réseau indépendant utilisant un transfert inter-génération normal entre la 4G et la 5G pour la continuité de service. Trois options de SA sont en cours de définition dans le 3GPP:

- ***Option 1*** utilisant EPC et l'accès LTE eNB;
- ***Option 2*** utilisant 5GC et l'accès NR gNB;
- ***Option 5*** utilisant 5GC et l'accès LTE ng-eNB.

B. Non-Standalone

Dans le scénario NSA, les cellules radio NR sont combinées avec des cellules radio LTE en utilisant la double connectivité pour fournir un accès radio et le réseau central peut être EPC ou 5GC selon le choix de l'opérateur. Ce scénario peut être choisi par les opérateurs qui souhaitent affecter des déploiements 4G existants, en combinant les ressources radio LTE et NR avec l'EPC existant et/ou qui souhaitent que la nouvelle 5GC fournisse des services mobiles 5G. Cette solution nécessitera un inter-fonctionnement strict avec le LTE RAN. L'expérience de l'utilisateur final dépendra de la ou les technologies d'accès radio utilisées.Trois options de NSA sont définies dans le 3GPP:

- ***Option 3*** utilisant EPC et un LTE eNB agissant en tant que maître et NR en-gNB agissant en tant que secondaire;
- ***Option 4*** utilisant 5GC et un NR gNB agissant en tant que maître et LTE ng-eNB agissant en tant que secondaire;
- ***Option 7*** utilisant 5GC et un LTE ng-eNB agissant en tant que maître et un NR gNB en tant que secondaire.

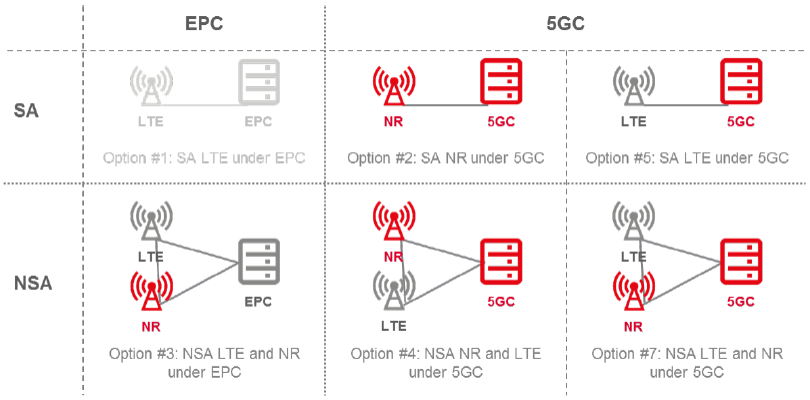

Fig. 8: Vue d'ensemble des options SA et NSA.[3]

IV. Les exigences de faible latence et de fiabilité ultra-élevées

Parmi les trois catégories ci-dessus, l'URLLC est la plus difficile car elle doit répondre à la fois à une faible latence et à une fiabilité ultra-élevée. Dans cette section, on expliquera les exigences en terme de latence et de fiabilité.

A. Exigence de faible latence

La latence de la couche physique T_L peut être divisée en cinq éléments suivants (Fig.9):

$$T_L = T_{ttt} + T_{prop} + T_{proc} + T_{retx} + T_{sig}, \tag{1}$$

T_{ttt} est le temps de latence de transmission, qui correspond au temps de transmission d'un paquet.

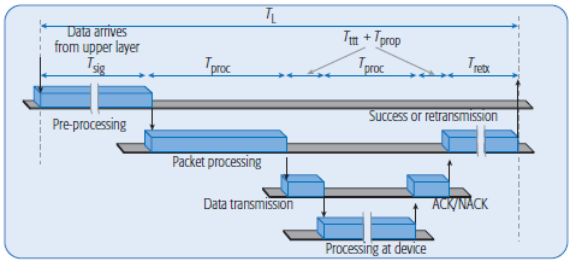

Fig. 9: Illustration des composants de latence.[4]

- T_{prop} est le temps de propagation du signal entre l'émetteur et le récepteur.
- T_{proc} est le temps pour effectuer le codage et le décodage, ainsi que l'estimation de canal lors de la transmission initiale.
- T_{retx} est le temps nécessaire à la retransmission.
- T_{sig} est le temps de pré-traitement pour l'échange de signalisation tel que la demande de connexion, l'octroi de planification, l'apprentissage et la rétroaction des canaux et le délai de mise en file d'attente.

Afin de réponde aux exigences de l'UIT, le 3GPP a décidé que la latence moyenne de l'URLLC devrait être inférieure à 0,5 ms[25]. Pour résoudre cette contrainte de latence stricte, le temps de transmission de paquet T_{ttt} doit être de l'ordre de centaines de microsecondes. Puisque T_{ttt} des systèmes 4G LTE actuels est une période de 1 ms, une nouvelle structure de trame réduisant T_{ttt} devrait être introduite. De plus, étant donné que la latence provoquée par l'estimation de canal et la rétroaction serait un goulot d'étranglement pour la transmission URLLC, un schéma de transmission qui ne repose pas sur les informations de canal doit être considéré.

B. Exigences de fiabilité ultra-élevées

Dans les systèmes 4G LTE, la fiabilité typique d'une transmission de paquets est de $0,99$. Deux ingrédients clés pour atteindre cet objectif sont le codage de canal (code convolutionnel et code turbo) et la retransmission partielle d'un bloc de transport erroné appelé requête de répétition automatique hybride (HARQ). De plus, les services URLLC nécessitent des meilleures performances, et en fait, la fiabilité

cible dans une période de $1ms$ devrait être d'au moins $0,99999$[25]. En outre, dans les applications critiques telles que la conduite autonome et la chirurgie à distance, la fiabilité devrait être aussi élevée que $1 - 10^{-7}$[15]. La première chose à faire pour répondre à ces exigences strictes est d'améliorer la précision de l'estimation de canal. Ceci est dû au petit gain de codage de canal pour un paquet court, de sorte que la perte causée par l'estimation de canal doit être évitée autant que possible dans le cas échéant. Cela se fait en ajoutant plus de ressources au pilote et en utilisant une technique avancée d'estimation de canal. Même dans ce cas, les performances URLLC requises peuvent ne pas être satisfaites, de sorte que des ressources supplémentaires dans les domaines de fréquence, d'antenne et spatiaux sont nécessaires pour améliorer la fiabilité. En outre, un schéma de codage de canal avancé adapté à la transmission de paquets courts doit être utilisé. Si la longueur de l'intervalle est très courte, un schéma de transmission répétitive utilisant des ressources du domaine temporel peut également être une option viable.

V. Faible latence: Solutions de la couche physique

Contrairement aux systèmes 4G LTE, les exigences de latence, de fiabilité doivent être prises en compte conjointement dans la 5G NR; par conséquent, il devrait y avoir un changement fondamental dans l'architecture de la couche physique (paquet, emplacement et trame). Plus précisément, une structure de paquet sensible à la latence pour un processus de décodage rapide et une structure de trame flexible pour prendre en charge le changement dynamique de la grille de ressources en fonction de l'exigence de latence sont nécessaires. De plus, lorsque le service URLLC est lancé, le paquet URLLC doit être transmis instantanément sans délai. Pour ce faire, un schéma d'ordonnancement minimisant la latence de transmission du paquet URLLC doit être introduite. En outre, étant donné que l'exigence de latence peut ne pas être satisfaite par la retransmission basée sur HARQ à moins que le TTI d'un paquet ne soit très court, un mécanisme qui réduit considérablement la latence de retransmission est nécessaire. En outre, une approche qui permet d'utiliser plusieurs interfaces radio pour réduire la latence peut être employée. L'idée de base de cette approche est de choisir la technologie d'accès radio (RAT) offrant la latence minimale parmi toutes les options possibles, y compris 4G LTE, 5G NR, WiFi et autres normes IEEE 802.x. En utilisant cela avec les communications de périphérique à périphérique (D2D), la latence de la couche réseau peut être considérablement réduite.

Dans cette section, on met l'accent sur les solutions de la couche physique pour URLLC, y compris la structure des paquets et des trames pour minimiser la latence. L'amélioration de la fiabilité et la réduction de la latence sont aussi importantes pour le succès d'URLLC. Cependant, lors de la réunion de

la norme 3GPP NR, un consensus s'est dégagé sur le fait que la question de la réduction de la latence doit être considérée en priorité. En effet, l'amélioration de la fiabilité peut être obtenue par l'élaboration de techniques 4G telles que le codage de canal, l'antenne, l'espace et les schémas de diversité fréquentielle, mais ce n'est pas le cas pour l'effort de réduction de latence[26], [27].

A. Structure du paquet

Le problème clé dans la conception des paquets URLLC est de minimiser la latence de traitement T_{proc} et le temps de transmission de la latence T_{ttt}. Notez que T_{proc} comprend le temps nécessaire pour recevoir les paquets, acquérir les informations du canal, extraire les informations de contrôle (planification), décoder les paquets de données et vérifier les erreurs. Dans les systèmes LTE, une structure de paquet de forme carrée est couramment utilisée pour une utilisation efficace du spectre sous un évanouissement de canal. Dans les systèmes 5G NR, un paquet non carré étiré dans l'axe des fréquences est utilisé comme ligne de base puisque cette structure minimise la latence de transmission T_{ttt}[28]. De plus, afin de réduire la latence T_{proc}, trois composants du paquets (pilote, contrôle et données) doivent être regroupés pour effectuer un traitement en pipeline de l'acquisition du canal, du décodage du canal de contrôle, et détection de données (Fig. 10). Un autre problème important à considérer est l'utilisation d'un schéma de codage de

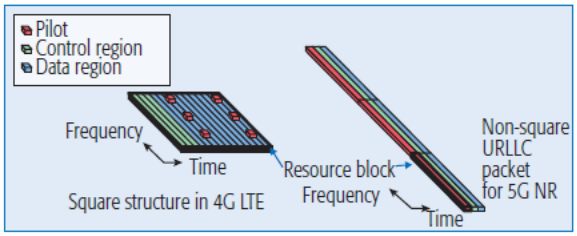

Fig. 10: Strucure du paquet.[4]

canal avancé. Dans les systèmes 4G, deux types d'approches ont été utilisés pour garantir l'exigence de fiabilité. Le premier type est le schéma de codage de canal (turbo et code convolutionnel) avec attachement de contrôle de redondance cyclique (CRC: cyclic redundancy check) pour le grand paquet. Le deuxième type consiste à utiliser un code simple (la répétition et le code Reed-Muller) sans attachement CRC pour le petit paquet. Dans la 5G NR, le code polaire et le code de contrôle de parité à faible densité (LDPC) ont été adoptés pour l'amélioration du canal de commande et de données, respectivement. Au fil des années, de nombreux efforts ont été faits pour améliorer les performances de décodage et la complexité de calcul (et donc la latence de traitement) de ces codes comme le décodage successif par liste d'annulation du code polaire et le décodage LDPC non binaire[27].

Une approche récemment proposée pour le second type est le codage vectoriel clairsemé (SVC:sparse vector coding), un schéma de transmission par paquets courts basé sur le principe de la détection compressée (CS:compressed sensing)[29]. L'idée de base de SVC est de mapper les informations sur la position d'un vecteur clairsemé $\mathbf{s}$. Notez que lorsque on choisit k positions dans un vecteur à n dimensions, les bits d'information $\lfloor \log 2 \binom{n}{k} \rfloor$ peuvent être codées. Par exemple, si $k = 2$ et $n = 9$, les 5 bits d'information peuvent être codés (par exemple, $s = [0\ 1\ 0\ 0\ 0\ 0\ 1\ 0\ 0]^T$). En étalant le vecteur épars $\mathbf{s}$ à l'aide des séquences d'étalement non orthogonales ci, $i = 1, \ldots, n$, on obtient le vecteur d'émission $\mathbf{x} = [\mathbf{c}_1\ \mathbf{c}_2 \ldots \mathbf{c}_n]\mathbf{s}$ dont la dimension m est inférieure à n (la dimension de $\mathbf{s}$). Comme $\mathbf{s}$ est un vecteur clairsemé et que k est connu à l'avance, le vecteur d'information $\mathbf{s}$ peut être récupéré via la technique CS[30]. Un avantage bien connu de la technique CS est qu'un vecteur d'entrée $\mathbf{s}$ peut être récupéré en utilisant un petit nombre de mesures (ressources). Étant donné que la complexité de calcul de l'algorithme de récupération clairsemée est proportionnelle à la clarté k, la latence causée par l'algorithme basé sur CS serait très marginale. Comme le montre la figure 11, le canal de commande de liaison descendante physique (PDCCH) avec SVC est efficace dans la transmission de paquets courts et surpasse PDCCH en utilisant le code convolutionnel dans les systèmes LTE-Advanced ($3.1\ dB$ à 10^{-5} PER (packet error rate)).

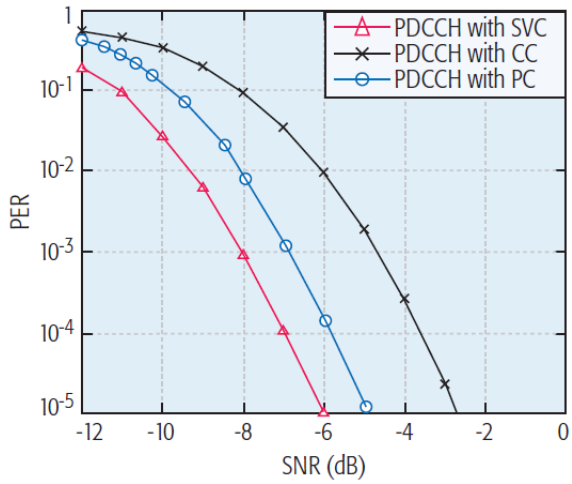

Fig. 11: PER de la transmission de paquets courts (12 bits) pour URLLC[4]

B. Structure de trame

L'un des principaux objectifs de la 5G NR est de concevoir une structure de trame unifiée pour couvrir une large gamme de bandes de fréquences et diverses catégories de services. À cette fin, une structure de trame flexible et un mécanisme de planification des utilisateurs ont été introduits. Une option directe pour

réduire le temps de latence de transmission T_{ttt} est de réduire la période de symbole (Fig. 12). Lorsque une bande de fréquence au-dessus de 6 GHz (onde millimétrique) est utilisée, en raison de la perte de trajet, le rayon de la cellule serait beaucoup plus petit que celui des systèmes cellulaires conventionnels, et donc l'étalement du retard de canal sera également faible. Dans ce cas, en contrôlant l'espacement des sous-porteuses, nous pouvons réduire la période des symboles (Fig. 13). Par exemple, la longueur du symbole peut être réduite de moitié (de 72 ms à 36 ms) en doublant l'espacement des sous-porteuses (de 15 kHz à 30 kHz). Ce faisant, le temps de transmission d'une sous-trame peut être réduit de moitié (de 1ms à $0,5$ ms). Cependant, lorsque une bande de fréquences inférieure à 6 GHz est utilisée, cette option peut ne pas être souhaitable en raison de l'étalement du retard important. Dans ce cas, on peut également envisager de réduire l'intervalle de temps de transmission (TTI) du paquet. Par exemple, en utilisant une transmission de niveau mini-créneau (slot level) (2 à 3 symboles) et de niveau créneau (mini-slot level) (7 symboles), T_{ttt} peut être réduit à 142, 241 et 500 ms, respectivement. En bref, en contrôlant la période de symbole et également le nombre de symboles dans un paquet, T_{ttt} inférieur à 1 ms peut être obtenu (le tableau de la figure 12). Notez que pour prendre en charge cette structure de trame flexible, un récepteur avancé équipé de fonctions de suivi rapide, de synchronisation rapide et de décodage simultané sont nécessaires.

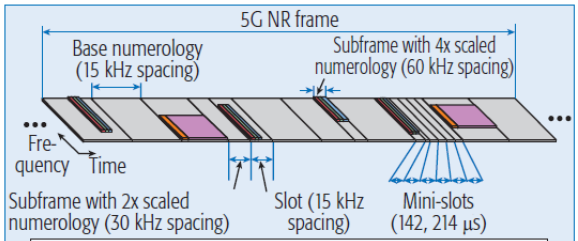

T_{ttt} (µs)			
Numerology	Subframe	Slot	Mini-slot
1x	1000	500	142/241
2x	500	250	71
4x	250	125	36

Fig. 12: Structure de trame.[4]

VI. Accès multiple non orthogonal (NOMA)

Afin de continuer à assurer la durabilité des services de communication mobile au cours de la prochaine décennie, de nouvelles solutions technologiques capables de répondre aux défis futurs doivent être identifiées et développées[31]. Pour le futur accès radio (FRA:Future Radio Access) à l'ère des années 2020, des gains significatifs en capacité et en qualité de l'expérience utilisateur (QoE) sont nécessaires

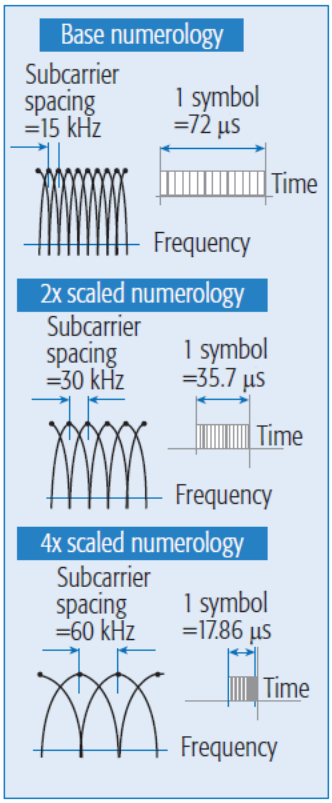

Fig. 13: numérologies pour la 5G NR.[4]

compte tenu de l'augmentation exponentielle prévue du volume du trafic mobile. Les technologies d'accès radio sont généralement caractérisées par des schémas d'accès multiples, par exemple, l'accès multiple par répartition en fréquence (FDMA), l'accès multiple par répartition dans le temps (TDMA), l'accès multiple par répartition de code (CDMA) et l'OFDMA, qui permet à plusieurs utilisateurs d'accéder et partager les ressources système simultanément. Dans les systèmes de communication mobile 3.9 et 4ème génération (4G) tels que Long-Term Evolution (LTE)[32] et LTE-Advanced[33], normalisés par le 3GPP, un accès multiple orthogonal (OMA) basé sur OFDMA ou single carrier (SC)-FDMA est adopté. L'accès multiple orthogonal est un choix raisonnable pour obtenir de bonnes performances de débit au niveau du système dans les services de domaine par paquets avec une conception de récepteur simplifiée. Cependant, afin d'augmenter encore l'efficacité spectrale à l'avenir, des conceptions de récepteurs plus avancées sont nécessaires afin d'atténuer les interférences intra-cellulaires et/ou intercellulaires. En tant que schéma d'accès multiple candidat pour FRA, on trouve un schéma d'accès multiple non orthogonal (NOMA) dans lequel plusieurs utilisateurs sont multiplexés dans le domaine de puissance du côté de l'émetteur et la séparation du signal multi-utilisateur du côté du récepteur. Cette dernière est effectuée sur la base de l'annulation des interférences successives (SIC: Successive Interference Cancellation).

Dans cette section, on explique le concept et les avantages de NOMA en tant qu'accès multiple potentiel pour FRA.

A. Concept du NOMA

L'une des principales techniques de NOMA est à travers le domaine de puissance, où différents niveaux de puissance sont alloués à chaque utilisateur pendant les transmissions de liaison descendante. Plus précisément, plus le gain du canal est élevé, plus le niveau de puissance est bas. La figure 14 illustre la liaison descendante NOMA avec SIC pour le cas d'une BS (station de base) et de deux UE (équipement utilisateur). La station de base émet un signal pour UE-i $(i = 1, 2)$, x_i, où $E[|x_i|^2] = 1$, avec la puissance

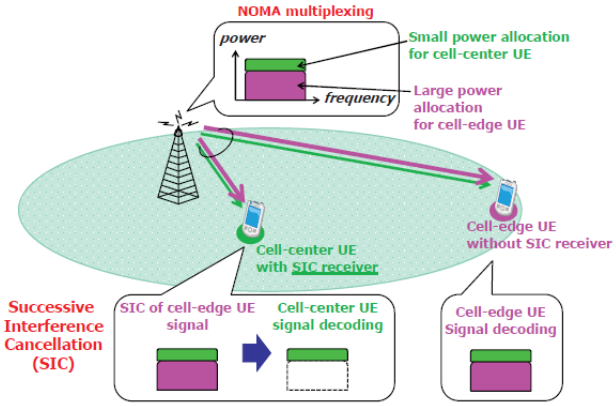

Fig. 14: Illustration de la liaison descendante NOMA.[5]

d'émission P_i et la somme de P_i est égale à P. Dans NOMA, x_1 et x_2 sont superposés dans le domaine de puissance comme suit

$$x = \sqrt{P_1}x_1 + \sqrt{P_2}x_2. \tag{2}$$

Ainsi, le signal reçu au niveau de l'UE-i est représenté par:

$$y_i = h_i x + w_i, \tag{3}$$

où h_i représente le coefficient de canal complexe entre UE-i et la station de base. Le terme w_i désigne le bruit gaussien blanc additif (AWGN), y compris l'interférence intercellulaire. La densité spectrale de puissance de w_i est $N_{0,i}$. Dans la liaison descendante NOMA, le processus SIC est implémenté au niveau du récepteur UE, dans le cas où le décodage du signal de l'UE souhaité ainsi que des signaux superposés d'autres UE est nécessaire. L'ordre optimal pour le décodage SIC est dans l'ordre de gain de canal décroissant normalisé par le bruit et la puissance d'interférence entre les cellules, $\frac{|h_i|^2}{N_{0,i}}$ (appelé simplement

gain de canal). Compte tenu de cet ordre de décodage et en supposant que tout utilisateur peut correctement décoder les signaux des autres utilisateurs dont l'ordre de décodage précède l'utilisateur correspondant, chaque UE-i peut supprimer l'interférence inter-utilisateur du j-ème utilisateur dont $\frac{|h_j|^2}{N_{0,j}} < \frac{|h_i|^2}{N_{0,i}}$. Dans le cas de deux UE, en supposant que $\frac{|h_1|^2}{N_{0,1}} > \frac{|h_2|^2}{N_{0,2}}$, l'UE-2 n'effectue pas l'annulation d'interférence car il vient en premier dans l'ordre de décodage. L'UE-1 décode d'abord x_2 et soustrait sa composante du signal reçu y_1, ensuite, il décode x_1 sans interférence de x_2. En supposant un décodage réussi et aucune propagation d'erreur, le débit de l'UE-i, R_i, peut être représenté comme suit:

$$R_1 = \log_2\left(1 + \frac{P_1|h_1|^2}{N_{0,1}}\right), \quad R_2 = \log_2\left(1 + \frac{P_2|h_2|^2}{P_1|h_2|^2 + N_{0,2}}\right) \tag{4}$$

D'après (4), on peut voir que l'allocation de puissance pour chaque UE affecte les performances de débit de l'utilisateur, la modulation et le codage (MCS) utilisé pour la transmission de données de chaque UE. En ajustant le rapport d'allocation de puissance, $\frac{P_1}{P_2}$, la BS peut contrôler de manière flexible le débit de chaque UE et également optimiser la capacité du système et l'équité de l'utilisateur.

B. Comparaison avec OMA

Pour OMA en tant que multiplexage utilisateur orthogonal, la bande passante de α $(0 < \alpha < 1)$ Hz est attribuée à l'UE-1 et la bande passante restante, $1 - \alpha$ Hz, est attribuée à l'UE-2. Le débit de l'UE-i, R_i, est représenté par:

$$R_1 = \alpha \log_2\left(1 + \frac{P_1|h_1|^2}{\alpha N_{0,1}}\right), \quad R_2 = (1-\alpha)\log_2\left(1 + \frac{P_2|h_2|^2}{(1-\alpha)N_{0,2}}\right) \tag{5}$$

Le gain de performance avec NOMA augmente par rapport à OMA. Par exemple, comme le montre la figure 15, dans le cas de deux UEs avec un UE à l'intérieur de la cellule et un UE au bord de la cellule, où $\frac{|h_1|^2}{N_{0,1}}$ et $\frac{|h_2|^2}{N_{0,2}}$ sont définis à 20 dB et 0 dB, respectivement. Pour les OMA, avec la même largeur de bande et la même puissance de transmission allouées pour les deux UEs ($\alpha = 0.5,\ P_1 = P_2 = \frac{1}{2P}$), les taux d'utilisateurs sont calculés selon (5) comme $R_1 = 3.33$ bps et $R_2 = 0.50$ bps, respectivement. D'autre part, pour NOMA, lorsque l'allocation de puissance est effectuée comme suit: $P_1 = \frac{1}{5P}$ et $P_2 = \frac{4}{5P}$, les taux d'utilisateurs sont calculés selon (4) comme suit: $R_1 = 4.39$ bps et $R_2 = 0.74$ bps, respectivement. Les gains correspondants de NOMA par rapport à OMA sont respectivement de 32% et 48% pour l'UE-1 et l'UE-2. Selon cet exemple de différence de SNR de 20 dB entre les deux UEs, il est montré que NOMA fournit un taux plus élevé que OMA.

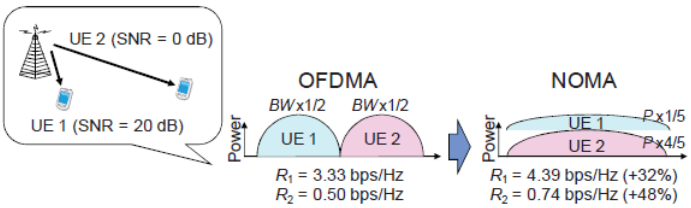

Fig. 15: Comparaison entre NOMA et OMA.[5]

C. Avantages et limitations de NOMA

Les avantages attendus par le futur système d'accès multiple NOMA sont les suivantes:

- Exploitation de la différence de gain du canal entre les utilisateurs;
- Non-orthogonalité intentionnelle à l'aide du multiplexage entre les utilisateurs dans le domaine de puissance et le traitement avancé au niveau du récepteur;
- Gain de performance robuste dans les déploiements pratiques sur une large zone et les scénarios de mobilité élevée.

Cependant, NOMA est une technique récente et est toujours en cours de développement. Il existe également plusieurs aspects qui peuvent limiter ceux qui doivent être résolus. Les plus importants sont énumérés ci-dessous:

- La complexité de calcul est plus élevée puisque chaque utilisateur doit décoder non seulement son propre signal, mais aussi le signaux des autres utilisateurs (pour appliquer CSI: Channel State Information), ce qui entraîne un délai plus long;
- Les informations sur l'état du canal (CSI) doivent être connues au niveau de la station de base, ce qui pourrait entraîner un sur-débit de rétroaction. Si des erreurs se produisent pendant le processus CSI, alors la probabilité d'erreur de décodage successif sera augmentée. Pour éviter une telle propagation d'erreur, le nombre d'utilisateurs utilisant les mêmes ressources doit être limité.
- Les utilisateurs regroupés doivent satisfaire des différences de gain de canal considérables afin d'améliorer le débit global, c'est pourquoi NOMA est souvent appliqué par paires.

VII. Radio Resource Management in 5G NR

Resource management has always been a key part of designing cellular communications, especially when there are limitations on the available resources. In cellular communications, the term “resource”, traditionally referred to spectrum and power. However, with the emergence of modern cellular networks along with the advent of new technologies, the term “resource” has gotten even more broad aspects; high demand for online computing services raised limitations on “computing” resources and hardware equipment along with required storage. Hence, nowadays, the term “resource” has much more broad aspects than that of the interpretations in the traditional cellular networks, e.g., 2G and 3G. Among those aforementioned terms, the term “spectrum” has always been at the center of designing concerns among all operators. Cellular networks sustained on their legs for decades by relying on so-called *sweet spectrum*, which refers to frequency bands between 500 MHz and 3000 MHz as illustrated in Fig. 16. This frequency band is unique and due to long distance travel capability while providing meaningful transmissions of data, operators are paying billions of dollars to own part of this spot, especially between 500 MHz and 1000 MHz. One can compare this sweet spot with the “location” term in real estate business joke; the most important components of real estate are location, location, location! Skyrocketing increase in the number of users and tremendous demand on data traffic caused cellular network operators to face challenges in accommodating their users’ needs with the satisfying Quality of Service (QoS). Fortunately, 5G New Radio (NR) unlocks much higher frequencies to support diverse end users with a variety of QoS requirements. While 5G NR promises high data rate and an ultra low latency, nevertheless, it does not come without challenges and cost. Achieving true 5G capacity requires massive installation of the equipment across the entire network as it requires utilizing mmWave spectrum. However, standardization units came across to an unanimous agreement that 5G should include the previous generations as the key part of the system, especially for the situations where a high coverage is needed, in which the sub-6 GHz would be good option, i.e., Fig. 17 illustrates the tradeoff between capacity and coverage with respect to different spectrum. As can be seen, the sweet spectrum is Sub-1 GHz, which is almost occupied by different operators. In the sequel, frame structure and numerology of 5G NR is briefly explained in subsection VII-A, subsection VII-B will go through the slot format in 5G NR and subsection VIII-B gives a brief glance on methodologies and challenges in 5G NR resource allocation with respect to different numerologies.

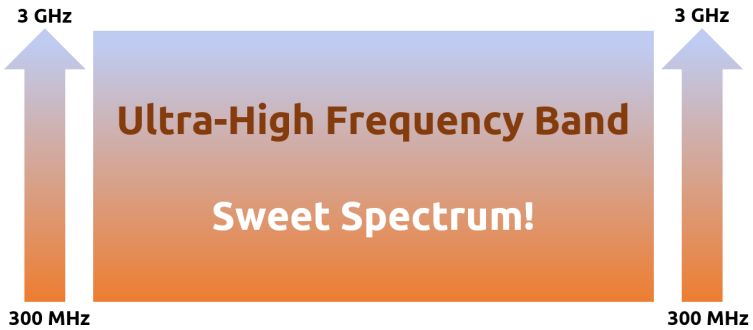

Fig. 16: Sweet spectrum for more than 4 decades.

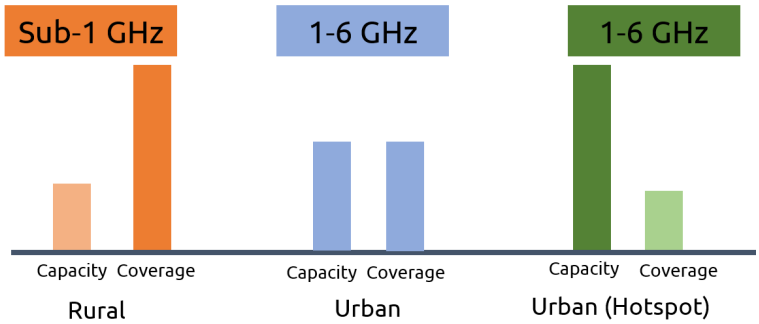

Fig. 17: Capacity and coverage of different spectrum.

A. *Numerology and frame Structure in 5G NR*

In contrast with the LTE cellular system, 5G NR brings more flexibility to accommodate massive number of users along with different service types and diverse Quality of Service (QoS) requirements. Beside variety of technologies in 5G, these capabilities are endowed by introducing new scalable resource partitioning called *5G NR Numerologies*. While the Resource Blocks (RBs) in LTE system are composed of 12 subchannel each with always 15 KHz bandwidth (total 12×180 KHz per each RB), RBs in 5G NR, with the same number of subcarriers yet can have different bandwidth depending on the numerology configurations and the requirements of the target service of interest. The very fist introduction on the frame structure is delineated in Fig. 18 along with details in the associated table, in which the parameter μ accounts for the numerology type. Technically, an RB of 5G NR can have bandwidth of 2^{μ} times of bandwidth of an RB in LTE. This means that $\mu = 0$ accounts for the RB in the LTE system. In overall, an RB in 5G comprises of one timeslot and 12 subcarriers with Sub Carrier Spacing (SCS) of $2^{\mu} \times 15$ KHz. Hence, an RB can accommodate bandwidth from 150 KHz to 720 KHz depending on the values of μ. Cyclic Prefix (CP) is the duration of the guard band.

Fig. 19(a) illustrates the slot-based frame for given numerologies. As can be seen, for every step of shrinking time slot, we have more bandwidth available. It is also possible to divide each time slot

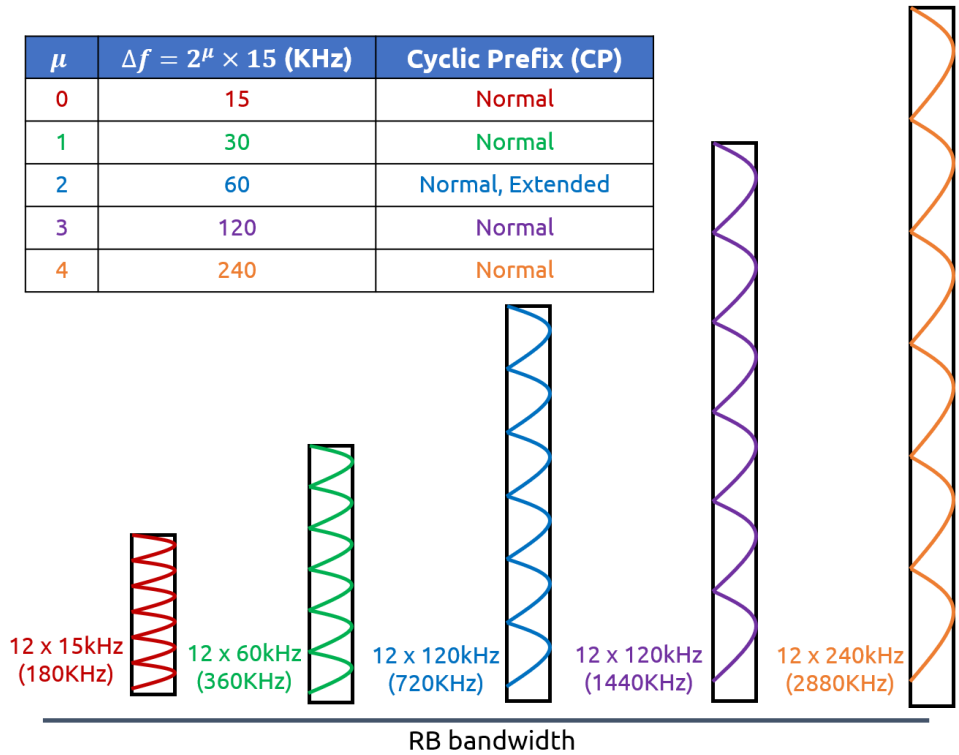

μ	$\Delta f = 2^{\mu} \times 15$ (KHz)	Cyclic Prefix (CP)
0	15	Normal
1	30	Normal
2	60	Normal, Extended
3	120	Normal
4	240	Normal

Fig. 18: Bandwidth of RBs for different numerologies.

into minislots as delineated in Fig. 19(b) to satisfy QoS requirements of delay-critical services such as ultra Reliable Low Latency Communications (uRLLC). This flexibility is endowed by splitting symbols between minislots, which means that less symbols can be transmitted within a short time to meet stringent latency requirement of some mission-critical applications, e.g., Safety-Oriented Applications of the Cellular Vehicle-to-Everything (C-V2X) communications. Observations on Fig. 19 implies that, given the type of the application, one can allocate resources by i) spanning in time domain while considering fix frequency band or ii) spanning in frequency domain while considering fix time duration. In the other words, one can allocate single minislot along with its spanning frequency domain available within each minislot or can allocate a frequency band by considering more than one minislot in the same frequency band. For example, for a mission-critical applications, it is more crucial to deliver/retrieve data within an stringent latency deadline, which means that the spanning in frequency domain by considering small minislot is more appropriate for this type of application. However, for an smart metering device, it is more efficient to allocate less frequency yet within more consecutive or nonconsecutive minislots. Table I shows the values for the time duration pf time-slots along with the number of slots to be accommodated within a subframe. Standardization organizations such as third Generation Partnership Project (3GPP) came across to new rules to utilize mmWave and sweet spectrum in more systematic way by using mixed numerology

resource allocation, in which different numerologies can be utilized for different applications [13], [34], [35]. Not all numerologies are suitable for all frequency bands. Table II shows the allowed SCS values

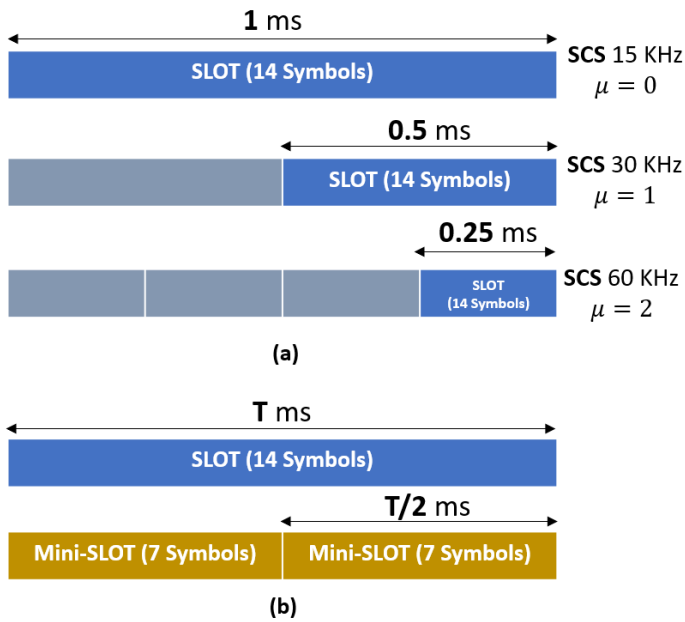

Fig. 19: Demonstration of (a) Slot-Based subframe and (b) Mini-Slot based subframe.

SCS Index (μ)	$\mu = 0$	$\mu = 1$	$\mu = 2$	$\mu = 3$	$\mu = 4$
Time duration of time-slot (in ms)	1	0.5	0.25	0.125	0.0625
Slots per subframe	1	2	4	8	16

TABLE I: 5G NR Numerology

for the important bands of sub-6 GHz and above 6 GHz.

	Sub-6 GHz	mmWave
SCS (MHz)	5/10/15/20/25/40/50/60/80/100	50/100/200/400
BW per carrier (KHz)	15/30/60	60/120/240

TABLE II: Sub-6 GHz and mmWave SCS and BW per carrier [13]

B. Slot Format and Time Duration

Fig. 20 demonstrates the bandwidth versus time duration for different numerologies along with the number of slots per frame ($N_{\text{slot}}^{\text{frame},\mu}$ in the second column of table in Fig. 20) and the number of slots per subframe ($N_{\text{slot}}^{\text{subframe},\mu}$ in the last column of table in Fig. 20, for the given numerology parameter μ. The frame and subframe structure has been delineated in more details in Fig. 21. The length of one radio frame is always 10 ms and the length of a subframe is always 1 ms, regardless of the numerology. Also,

the number of symbols within each slot is always 14 symbols unless the structure is based on minislot (as in Fig. 19(b)).

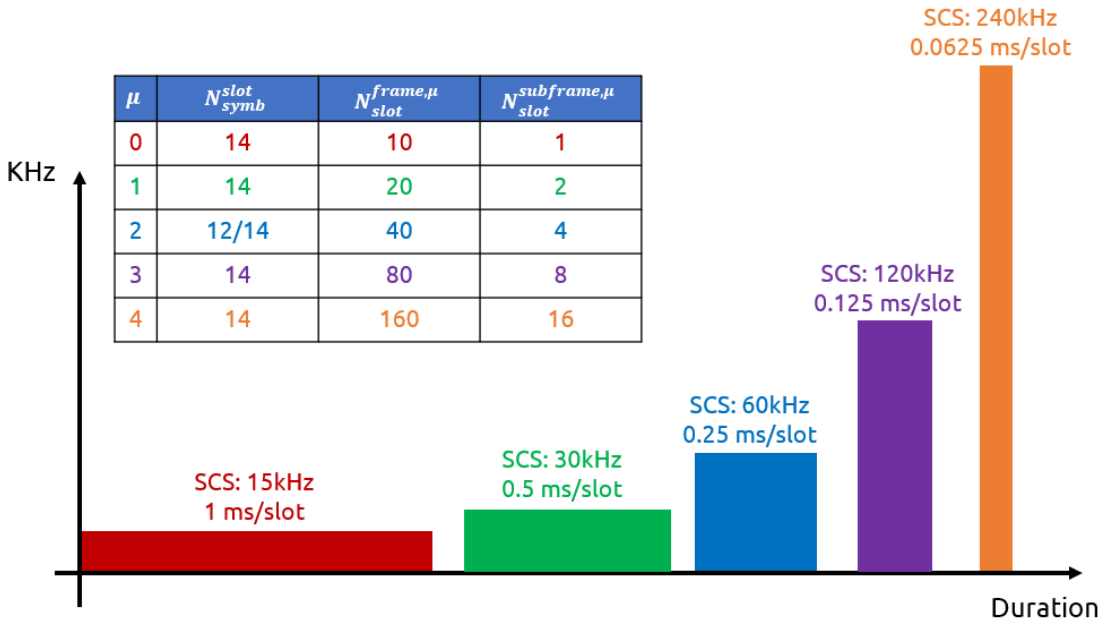

μ	N_{symb}^{slot}	$N_{slot}^{frame,\mu}$	$N_{slot}^{subframe,\mu}$
0	14	10	1
1	14	20	2
2	12/14	40	4
3	14	80	8
4	14	160	16

Fig. 20: Relationship between the duration and and the number of slots within a frame.

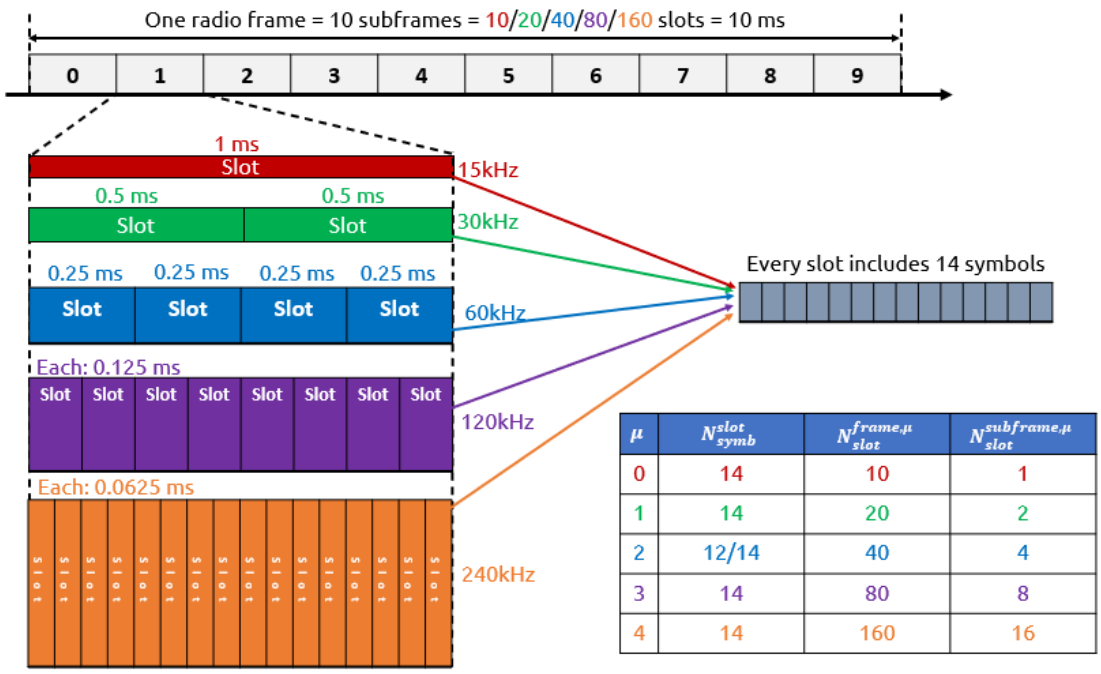

μ	N_{symb}^{slot}	$N_{slot}^{frame,\mu}$	$N_{slot}^{subframe,\mu}$
0	14	10	1
1	14	20	2
2	12/14	40	4
3	14	80	8
4	14	160	16

Fig. 21: Frame Structure based on different numerologies.

VIII. Which Numerology and When: Resource Allocation in 5G NR

The unique capability of resource management in 5G NR in comparison with the previous generations, is to utilize different numerologies and even mixed-numerology resource allocation depending on many

conditions in the end-to-end resource allocation procedures. 5G NR is flexible of choosing appropriate numerology to fit the dynamic conditions. It is unlikely to choose a high bandwidth RB numerology for the communications that desire better coverage, to choose a low bandwidth numerology for the communications that a very low latency is required. In fact, since 5G system is more than a infrastructure for the traditional mobile communications, system should be able to adopt different type of RBs for different purposes. There are many factors involved in such decisions and Fig. 22 sketches the relationship between a a few factors. As can be seen, cell-size achievable latency are strongly related to the carrier frequency. It is noted that the low latency can also be achieved in larger cells using wider subcarrier spacing. However, this may incur a performance penalty in terms of reliability or throughput [6].

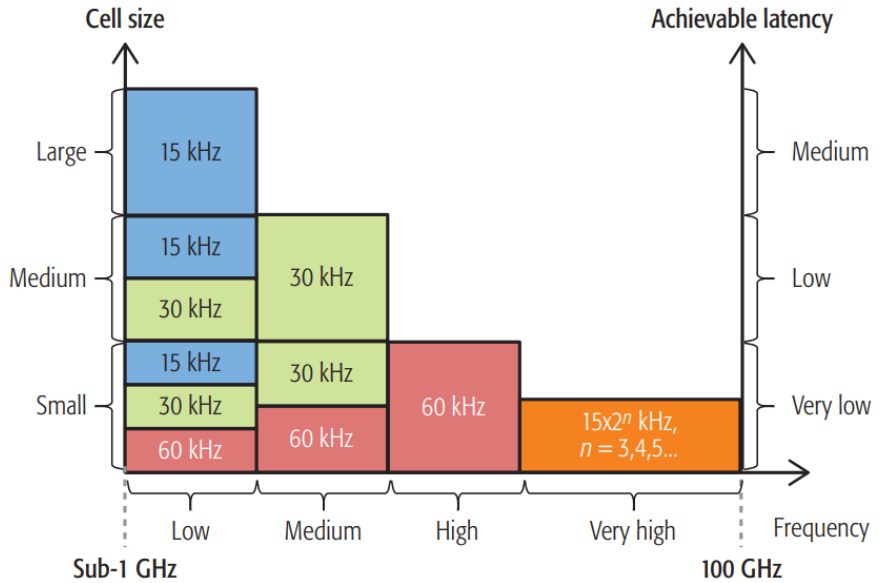

Fig. 22: OFDM numerology design for wide range of carrier frequencies, deployment types, and application latency requirements using regular slots [6].

Fig. 23 illustrates the optimal subcarrier frequency ($f_{\rm sc}$ (KHz)) and optimal number of symbols $n_{\rm D}$ versus Doppler shift (Hz) [7]. Simulation results in [7] demonstrate that in higher mobility conditions with high SNR regimes, the choice of numerology is much more important than that of the conditions where there is lower mobility, and the choice of numerology has a major impact on the achievable *effective capacity* [36]. Technically, in 5G NR, numerology design is based on the service type, service requirements, and user requirements, and this is what makes 5G quite different from the previous generations. Table III shows the key requirements for different service types [14]. For instance, uRLLC service with low latency requires shorter Transmission Time Interval (TTI), which is the duration of the transmission on the radio link. Or, for the uRLLC service type with high reliability, time duration of the Cyclic Prefix

(T_{CP}) should be long, as it is necessary to deal with the Inter Symbol Interference (ISI) as well as intra-symbol interference. The guard time should be long enough to avoid overlap between the symbols in the frequency domain. Table IV shows the requirements to deal with the important constraints for different impairment types, i.e., channel and RF hardware. This table also implies that there are many factors in designing the desired numerology to meet user requirements. For instance, we can combat larger Doppler shift by designing having larger Δf, which is larger subcarrier spacing. This argument well fits with the results demonstrated in Fig. 23 obtained by [7]. Coexistence of different numerologies has advantages and

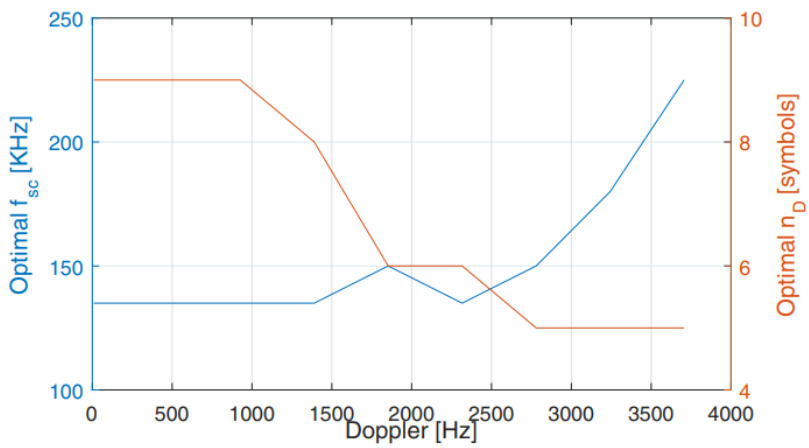

Fig. 23: Optimal subcarrier spacing frequency versus Doppler effect [7]

TABLE III: Service requirements and their effects numerology parameters [14].

Service Type	Key Requirement	If any, key necessities for numerology design				
		η_{spectrul}	Δf	# of subcarriers	TTI	T_{CP}
eMBB	High Throughput	High				
	High Data Rate	High				
mMTC	Support for small data bursts		Large			
	High energy efficiency			Low		
uRLLC	Low latency				Short	
	High reliability		Large			Long

TABLE IV: User requirements and their effects numerology parameters [14].

Impairment Type	Important Constraint	If any, key necessities for numerology design				
		η_{spectrul}	Δf	# of subcarriers	TTI	T_{CP}
Channel	Doppler		Large			
	Multipath					Long
	pathloss			Low		
RF Hardware	Phase noise					
	Frequency offset		Large			
	PA none-Linearity		Large	Low		

disadvantages, which forms the basis of the next subsection. However, before moving to make discussion on challenges, let us take a quick review on the resource allocation in frequency and time domain based on 5G NR.

A. Time and Frequency Domain Resource Allocation in 5G NR

According to specifications in [9], here is the brief summary of time and frequency domain resource allocation in 5G NR.

a) Time-Domain: 5G NR supports the one-slot, minislot, and multiple slot resource allocation. Minislot can accommodate 2, 4, or 7 OFDM symbols. Duration depends on the numerology and SCS. Namely, the higher SCS, leads to lower duration (as illustrated in Fig. 19), which is suitable for the uRLLC transmissions. However, the downside of the lower duration is that it also impacts the CP, which can cause lower coverage. That's why such implementation is much useful for compact cells. 5G gives symbol-level scheduling possibility. While in the LTE system, everything is reffered to TTI, which is equal to 1 ms. Hence, with 5G, this procedure can be very flexible.

b) Frequency-Domain: Even though the RB structure, as explained in the previous sections, is similar to LTE (12 subcarriers), however, while 5G supports the active types within the LTE system, it also brings more flexibility. There are two types of resource allocation in frequency domain; *Type 0*: this type is none-distributed allocation in frequency domain. RBs forms RB Groups (RBGs), in which the number of RBs per group depends on the bandwidth. This type utilizes none-interleaved mapping between virtual RBs and physical RBs. *Type 1*: This is a distributed resource allocation and the interleaving is an open option, which can be either utilized or ignored. *Dynamic Switching*: making switch between two types and this capability is new in 5G NR and LTE system does not support it. It allows to make switch between two types depending on the conditions. In practice, the type is determined by the Downlink Control Information (DCI).

B. Some Challenges and Ongoing Efforts to Resolve Them

Even though 5G NR provides highly flexible numerology for the resource allocation, nevertheless, there are some drawbacks using this technology. We already heard terms Inter Symbol Interference (ISI) and Inter Carrier Interference (ICI). The term Inter Numerology Interference (INI) is a new type of interference comes with 5G NR numerology, which induces interference between multiple numerologies

due to coexistence of multiple numerologies, which deteriorates the system performance. In the sequel, some efforts to resolve this issue are highlighted.

1) Interference Pattern Derivation: Existing works, to name a few, [37]–[39], recently aimed to deal with this issue. By dividing the INI into a dominant deterministic part and an equivalent noise part, authors in [37] proposed scheme to cancel the dominant interference, and the residual interference power is utilized as effective noise variance for the calculation of log-likelihood ratios for bits. An investigation is done by [38] to obtain the interference pattern and the results reveals that the variance of interference energy increases due to the difference in SCS. By deriving radiation pattern in massive MIMO-OFDM downlink system in [39], it has been shown that by utilizing the proposed precoding, INI appears only in frequency selective channels. Besides, the transmission of users using numerology with large SCS is always with the best quality.

2) Filtering & Guard Band Design: To name a few, [8], [40]–[43]. It has been shown in [40] that a filtered OFDM (F-OFDMA) system accommodates the coexistence of the mixed numerologies better than that of the none-filtered counterpart. Combining F-OFDM with MIMO in [41] further improves the system capacity. The key challenge is to choose (optimize) an appropriate CP length such that it consumes less amount of time and at the same time, combats ISI and ICI. The F-OFDM MIMO system with the optimized CP outperforms conventional OFDM system. Designing an spectral-usage efficient Guard Band (GB) is targeted in [42], which reduces the GB spectrum utilization by %50 while achieving the same error rate as the conventionally implemented GB. The follow-up work [43] put the same idea yet by analyzing INI and deriving outage probability of each subcarrier. Finally, the authors in [8] optimized the GBs in the adjacent bands as shown in Fig. 24, with respect to SCS, service requirement, and power offset between numerologies.

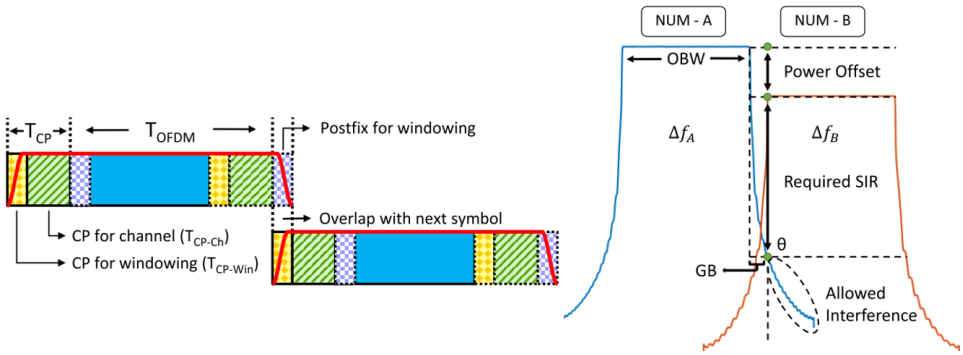

Fig. 24: Adaptive guardband design in [8]

3) Scheduling: [44] Another solution might be utilizing efficient scheduling schemes as the 5G NR provides very flexible scheduling operations on time slots. The authors in [44] investigated the scheduling problem which determines how time-frequency resources of different numerologies can be allocated to support heterogeneous services in 5G wireless systems, with the goal of scheduling as many users as possible while meeting their required service delay and transmission data. Since 5G brings many interesting technologies such as beamforming, massive MIMO, SCS, dual connectivity, supporting wide range of end users in different categories of uRLLC, eMBB, and mMTC, all of these technologies makes 5G scheduling different from the LTE counterpart. However, similar to LTE, 5G has shared channel and control channel. UEs either in connected mode or idle mode, should properly understand and receive system information such as paging and other procedures to make decision on "which frequency and/or time" should UE utilize to receive the shared channel information in DL. This procedure begins by transmitting the DCI to the UE, which is carried by the PDCCH channel. Similar procedure is done for the UL by transmitting Uplink Control Information (UCI), which is carried by PUCCH. The main difference with the LTE counterpart is that in the LTE system, the control region is occupied the whole bandwidth within a subframe, however, in 5G NR, control region is localized within bandwidth. We call this control region in both LTE and 5G NR as Control Resource Set (CORESET). Technically, available RBs in cellular network is being distributed between Uplink (UL) and Downlink (DL) such that except for $\mu = 4$, in which the maximum number of available RBs is 138, for the values of $\mu \in \{0, 1, 2, 3\}$, the minimum (maximum) number of RBs in UL/DL is 24 (275) RBs, respectively. 5G NR has more flexible ways to configure subframe. In the LTE system, all symbols within the subframe should be used for UL (DL) if the subframe is allocated for UL (DL). However, 5G NR provides extremely flexible ways to configure slot format through many combinations [13], [34], [35]. In fact, symbols within a slot can be utilized in different ways for either UL or DL transmissions. This makes the scheduling procedures in 5G system much more flexible than that of the LTE system, and it can be utilized to combat INI. For instance, for a slot (includes 14 symbols) dedicated for the UL transmission, first symbol within this slot can be used for the DL control mechanisms while the rest of 13 slots are being consumed for the UL transmission; an opposite usage of this example is also possible. Studying the 5G NR specifications in [9] implies that there are no fixed UL/DL configurations as already been for the previous generations. Instead of predefined UL/DL configurations as in LTE configurations, 5G NR comes with the slot format as described in previous sections and defines 62 different slot formats as illustrated in Fig. 25 and they

basically allow very flexible configurations on how we utilize the available spectrum. Technically, here is the configurations for the Frequency Division Duplexing (FDD) and Time Division Duplexing (TDD).

- FDD utilizes only slot format “0” (DL) or slot format “1” (UL), depending on the direction of the transmission.
- however, for the TDD, the information should be provided to the device, so the device knows when to transmit and when to receive data. There are multiple ways to do that: either via dedicated signaling connection, which is through the RRC layer, or by the DCI transmitted on the control channel Physical Downlink Control Channel (PDCCH), i.e., through scheduling indicator, in which the DCI information contains the slot format indicator, which points to the particular table as shown in Fig. 25.

Format	Symbol number in slot													
	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	D	D	D	D	D	D	D	D	D	D	D	D	D	D
1	U	U	U	U	U	U	U	U	U	U	U	U	U	U
2	X	X	X	X	X	X	X	X	X	X	X	X	X	X
...	...													
32	D	D	D	D	D	D	D	D	D	D	X	X	U	U
...	...													
61	D	D	X	X	X	X	U	D	D	X	X	X	X	U
62-254	Reserved													
255	UE determines the slot format for the slot based on TDD-UL-DL-ConfigurationCommon, or TDD-UL-DL-ConfigDedicated, if any, on detected DCI formats													

Fig. 25: UL/DL allocations and slot formats in 5G NR; table is abstracted from [9].

As can be seen from this table, there are 62 different formats.

IX. Concluding Remarks and Potential Open Research Directions

As discussed in this part of the report, while 5G NR comes with many flexibilities along with variety of capabilities, yet it brings new challenges into the table that need to be addressed. Many research directions took directions to battle INI impact when employing multi-numerologies. Some potential research directions, to the best of our knowledge and not stated in the existing literature, are as follows:

- Even though well-known and standard modulation techniques are used to model PHY layer performance, nevertheless, recent studies shows that the type modulation jointly with choosing numerology could have impact on system performance and this potential direction has been addressed

precisely to see how and when the joint modulation and numerology selection can affect the system performance.

- Some INI cancellation techniques are being utilized to combat INI, however, most of them are much similar to those techniques have been utilized in the traditional interference mitigation approaches and it is not clear how those techniques can capture the signal processing perspective in a multi-numerology system. New techniques that could capture the signal processing design perspectives to cancel the INI can be an interesting research direction.
- A comprehensive INI analysis comprising all affecting factors is missing in the literature. A new analysis can be proposed by targeting joint Guard Band, Power offset, windowing, number of subcarriers , and subcarrier spacing .

X. Massive MIMO et connexion D2D

A. Massive MIMO

Le 5G a été conçu pour pouvoir dépasser son prédécesseur (le 4G) dans tous ces aspects. Il doit être capable d'avoir 1000 fois la capacité, utiliser moins d'énergie, diminuer la latence, etc. C'est pourquoi il est nécessaire de développer des nouvelles techniques qui nous permettent d'atteindre ces buts technologiques. Nous allons donc aborder 2 techniques qui sont en développement pour l'amélioration de la connexion et du débordement de données dans le 5G. Étant donnée que le nombre d'usagers augmente à chaque année, nous devons utiliser des techniques comme le massive MIMO ou le D2D (device to device) pour essayer de limiter la charge de paquets dans les antennes.

Le massive MIMO est un système MIMO à une plus grande échelle, soit des centaines d'antennes, voir des milliers d'antennes, pour effectuer le même travail. L'utilisation de massive MIMO dans le 5G est maintenant une obligation étant donné les applications que nous voulons implémenter nécessitte une implémentation de cette nouvelle norme. Dans le 4G, les systèmes générals MIMO étaient encore utilisés et permettaient une bonne fiabilité dans les réseaux. Cependant, cette technologie n'est maintenant pas capable de nous permettre une utilisation fiable d'un réseau 5G. Avec l'utilisation du massive MIMO, nous pouvons augmenter la capacité peut être augmenter d'un facteur 10 et l'efficacité énergétique irradié par un facteur 100. [10]

L'utilisation de MIMO à usagers multiples permet d'obtenir de grands avantages comparé au MIMO conventinnel point à point. Celui-ci fonctionne avec des antennes de faible qualité, un environnement de diffusion riche n'est pas requis pour l'utilisation de ce système. L'allocation des ressources est simplifiée puisque toutes les antennes actives utilisent toutes leurs ressources en temps et en fréquence. Les antennes d'extra permettent l'utilisation de composante à faible puissance et et coût réduit puisque nous n'avons plus besoin d'utiliser des antennes à haut gain et a grand coût. Il permet aussi de réduire la latence, de simplifier la couche MAC et aussi augmenter robustesse du circuit par rapport au effet de jamming. Les antennes d'extra nous permettent aussi de focuser l'énergie dans des plus petites divisions d'espace pour améliorer considérablement efficacité énergétique émise. Ceci est possible puisque nous avons plus de degrés de liberté dans la malléabilité du spectre de transmission, puisque nous avons plus d'antennes. En augmentant le nombre d'antenne nous pouvons aussi clairement améliorer la réponse en fréquence ainsi que la réponse spatiale du système. Plus nous augmentons le nombre d'antenne, moins les atténuations subites auront des impacts importants sur la réception du signal. En effet, lorsque nous avons des atténuations

dans le canal de réception, ceci est dût à des interférences destructives du signal reçu. En augmentant le nombre d'antenne, nous augmentons le nombre de chemins possible pour le signal, réduissant ainsi la probabilité d'avoir une atténuation forte sur l'ensemble des antennes. Pour avoir un bon multiplexage spatiale, les stations de base doivent avoir une bonne connaissance du canal en uplink et en dowlink. Nous ne pouvons malheureusement pas utiliser la méthode d'envoyer une onde standards pour estimer le canal avec un système massive MIMO, lorsque nous évoluons dans un système à mouvement rapide. Ceci est dût au fait que les systèmes massive MIMO nécessite beaucoup plus de resources en fréquence et en temps que qu'un MIMO normal. De plus, étant donné que nous avons beaucoup plus d'antennes, il y autant de canaux possible entre ces antennes et un usager, ce qui augmente beaucoup le temps de calculation. Ceci nous indique donc que le uplink nécessiterait environ 100 fois plus d'allocations de ressources qu'è la normale.

Plusieurs codes sont utilisés pour effectuer une gestions efficace des usagers et des antennes pour le Massive MIMO. Les codes les plus couraments utilisés sont les codes ZF (zero forcing) et les codes MRC. Les codes MRC sont vu comme étant les codes les plus faciles à implémenter pusiqu'il est seulement nécessaire d'effectuer une multiplication du signal avec la conjugué du canal de réception. Ce système n'est cependant pas le plus efficace lorsque nous voulons augmenter l'énergie efficace spectrale. Le code ZF a une moins bonne efficacité énergétique à plus base efficacité spectrale mais il dépasse de loin les performances du codage MRC lorsque nous voulons augmenter l'efficacité spectrale du système.

Nous voyons aussi donc que l'efficacité énergétique est beaucoup plus grande dans les systèmes massive MIMO que les MIMO normals. L'utilisation du codage nous permet aussi d'augmenter cette efficacité.

B. Connexion D2D

Nous allons maintenant voir l'utilité d'utiliser une technologie comme le D2D pour permettre désencombrer les antennes. Donc comme le nom l'indique, le D2D est une connexion d'usager à usager sans passer par l'antenne de base, comme il est traditionnellement imposé lors de la transmission d'informations. Cette technique nous permet d'augmenter le nombre d'usagers possible pouvant se connecter ensemble pour le même nombre d'antennes en service.

Nous pouvons voir que ce système coexiste avec le type normal de communication, il permet cependant d'effectuer des tâches qui ne sont pas possibles traditionnellement. Par exemple, nous sommes capable d'établir un lien usager-usager qui nous permet de partager le même canal vers l'antenne. Ceci nous assure que si un des usagers n'est pas dans une bonne position pour avoir un canal adéquat ou qu'il se situe

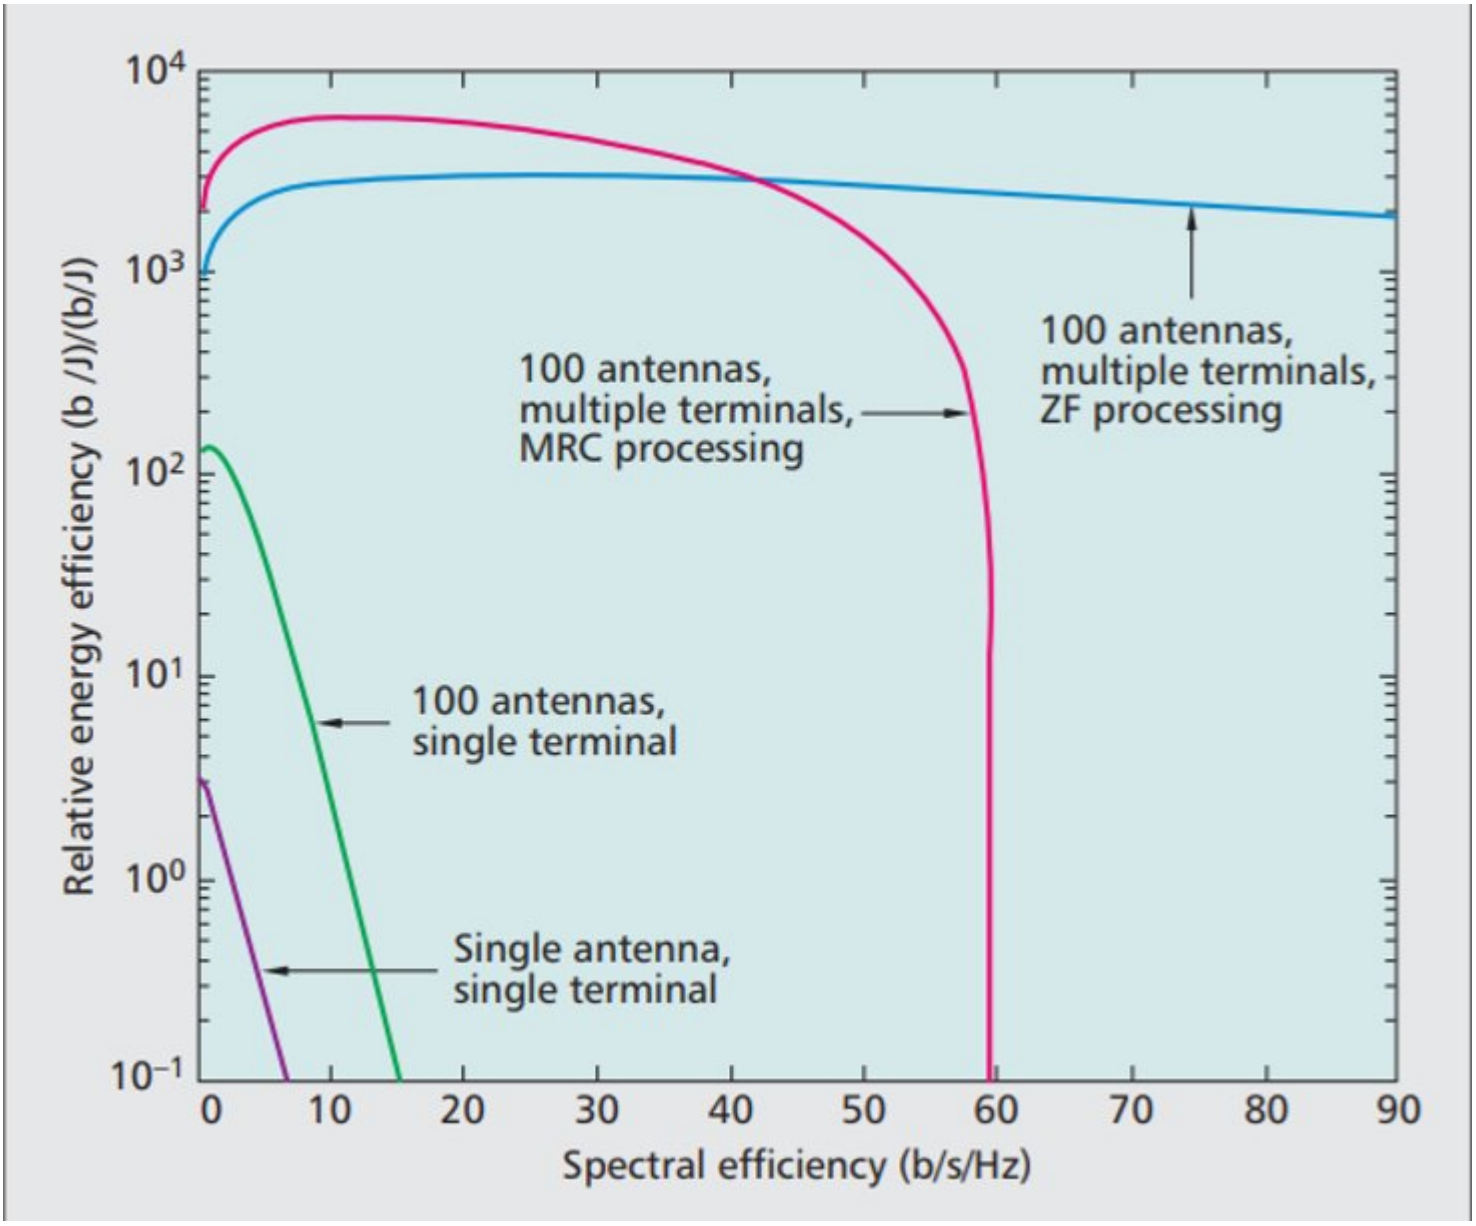

Fig. 26: Efficacité énergétique en fonction de l'efficacité spectrale des différents codes [10]

loin de son antenne de base, celui-ci pourra envoyer son information l'autre usager auquel il est connecté pour que celui-ci envoie l'information à la station de base dans un bon canal et avec un bon débit. Bien évidemment, les deux usagers doivent avoir une bonne connexion entre eux pour pouvoir effectuer se type de connexion, ils doivent donc être relativement proches l'un de l'autre pour la connexion soit efficace.

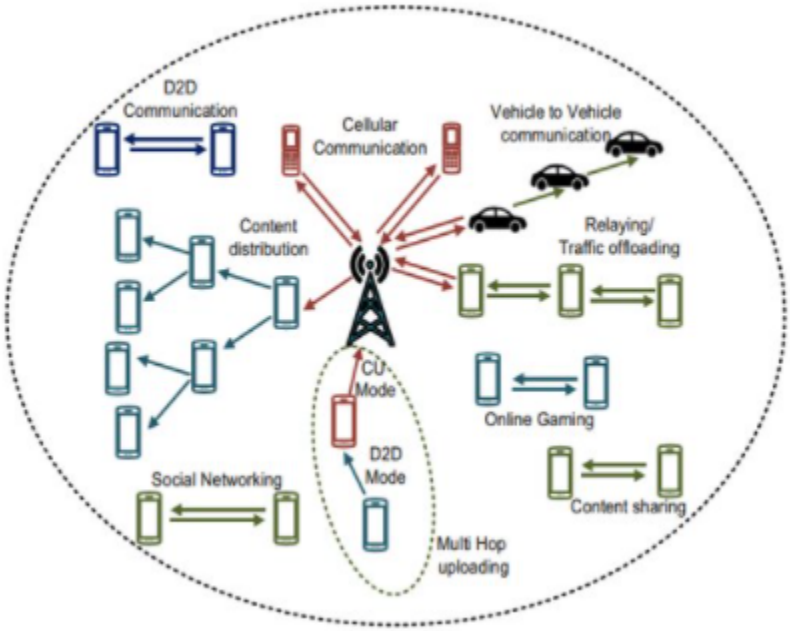

Fig. 27: Vue d'ensemble du système de communication D2D [11]

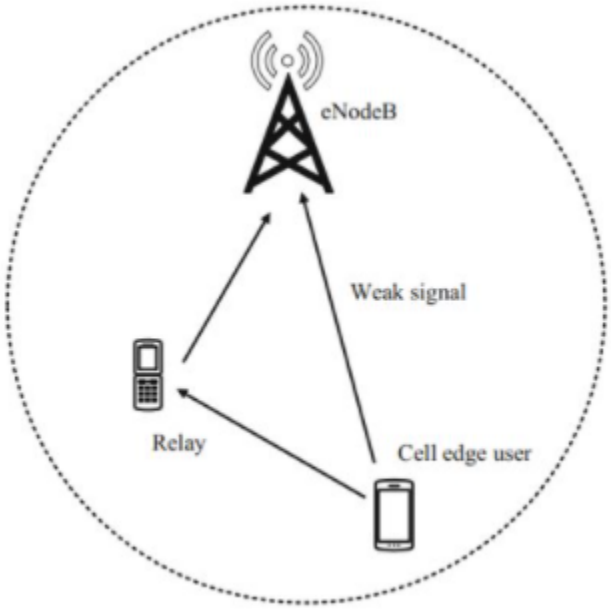

Fig. 28: Utilisation d'un usager comme relai pour l'antenne [11]

Nous pouvons aussi effectuer l'envoi direct de données d'usager à un autre sans passer par l'antenne, diminue la latence engendrée par le passage dans l'antenne. Nous avons donc une transmission rapide des données, nous diminuons aussi la charge des stations de bases tout en augmentant l'efficacité énergétique puisque nous avons besoin de moins de puissance pour transmettre nos données puisque nous avons une petit distance entre usagers.

Nous pouvons classifier la connexion D2D en deux sous classifications, les inband et les outband D2D connections. [11]

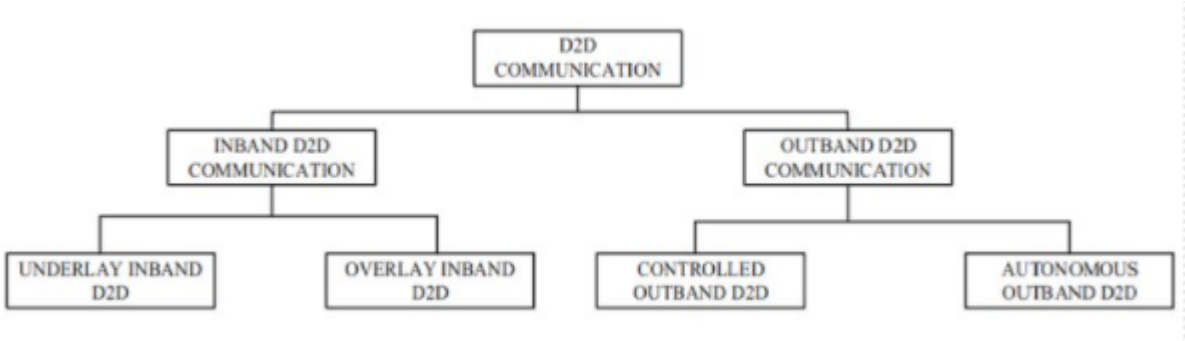

Fig. 29: Type de communication D2D [11]

Dans le premier type de communication, Inband, nous utilisons le spectre de fréquence standard que nous utilisons pour les communications habituelles. Il est donc plus facile d'avoir un contrôle sur le spectre et de ne pas se préoccuper de gérer les interférences entre usagers. Ce type peut aussi être à son tour séparer en deux section, comme nous le voyons à la figure 29, soit Underlay Inband et Overlay Inband. Dans le Underlay Inband nous avons une connexion qui permet aux deux usagers d'utiliser la même bande de base lors de leurs échanges d'informations. Ceci peut causer certains problèmes d'interférence, puisque les deux usagers peuvent envoyer de l'information en même temps. Dans l'autre type, le Overlay Inband, nous divison le spectre en deux parties égales de sorte à ce qu'il n'y est jamais d'interférences lors de la transmission, nous avons cependant moins de bande passante.

Le Ourband D2D est cactérisé par sa largeur de bande or des spectres normals de transmission, il se situe dans la même catégorie que le WIFI direct et le bluethooth. Nous avons donc un moins grand contôle sur le spectre utilisé. Nous devons aussi gèrer les interférences par nous-même et nous n'avons aucune certitude que le signal ne sera pas brouillé par une autre source inconnue. Le Outband est lui aussi divisé en 2 parties, Controlled Outband et le Autonomous Outband. La différence entre les deux est que toute la gestion des connexions est gèré par l'antenne pour le Controlled Outband, alors que pour le Autonomous Outband, c'est les usagers qui controllent les connexions. [11]

Bien que nous ayons beaucoup d'avantages pour D2D, nous avons aussi quelques inconvénients. Par exemple, il est quand même assez difficile de trouver un usager auquel on peut se connecter. Vu que les usagers sont toujours en mouvements, nous ne pouvons pas toujours rester connecter au même usager, se qui provoque une augmentation du nombre de signaux envoyés pour essayer de se connecter. Cela crée

donc à son tour des potentielles interférences. Nous ne pouvons donc pas seulement nous baser sur cette méthode pour effectuer la majorité de nos connexions.

XI. Beamforming: Overview and Benefits

Now that we understand how massive MIMO works, we can finally see how we can leverage these multiple inputs and outputs to perform beamforming. The main concept of beamforming is the creation of beams which are directed to the user equipment, instead of transmitting in all directions. This comes with many advantages such as enhanced energy efficiency, improved spectral efficiency, and increased system security. Moreover, beamforming can be implemented easily in millimeter-waves (mmWave). This is because of the high frequency, hence small wavelength, of these waves and the ability to construct smaller antennas and fit them in smaller areas as a result. All of this is explained in [10]. Furthermore, we can also find different techniques to apply beamforming in practice. We start by discussing the benefits of beamforming in this section.

A. Enhanced Energy Efficiency

The use of beamforming with massive MIMO allows us to increase the energy efficiency. This is due to the fact that transmitting signals to a particular user in directed beams requires low power since the energy is focused in a single direction rather than being sent in all directions. We can see how the energy is directed in the Fig. 30. To explain further, beamforming works by allowing the transmitted signals from each antenna to interfere constructively in the required direction, and destructively everywhere else. As a result, due to constructive interference, we can transmit less energy per antenna while maintaining the required received power at the receiver.

To demonstrate the enhanced energy efficiency while using beamforming, we compare the performance between conjugate beamforming and zero-forcing and note their strengths and weaknesses. [45] provides detailed formulas for the energy efficiency, and it puts forth comparisons between the two previously mentioned techniques. First, we define the energy efficiency as:

$$\eta_l = \frac{\sum_{k'=1}^{K_l} \theta_{lk'}}{\frac{P_{rad}}{2\epsilon_p}(1 - \frac{\tau_u}{T}) + \frac{2R_{flops,l}}{a} + M_l b}$$

For the purpose of our study, we will only focus on two main terms: the numerator represents the total throughput for cell l, P_{rad} represents the radiated power, and M_l represents the number of antennas at the

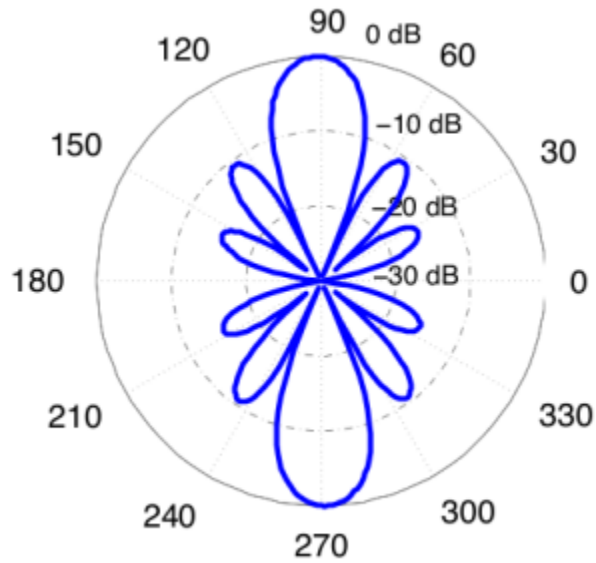

Fig. 30: Sample radiation pattern after beamforming taken from [12]

base station (BS) of cell l. Increasing the efficiency, hence, is synonymous to increasing the throughput while decreasing the radiated power. Yang and Marzetta show that we can find an optimal value for M in different situations for different techniques (cb and zf).

TABLE V: Total energy efficiency for an optimal number of antennas M

P_{rad} (Watt)	0.5	1	2	4	8
$\overline{M}^{cb\star}$	18	22	29	40	57
$\overline{M}^{zf\star}$	68	61	59	63	72
$\overline{\eta}^{cb\star}$ (Mb/J)	6.01	7.14	7.35	6.7	5.57
$\overline{\eta}^{zf\star}$ (Mb/J)	5.04	6.65	7.71	7.84	7.03
$\theta_{50}^{cb\star}$ (Mb/s)	1.95	3.07	4.56	6.37	8.48
$\theta_{50}^{zf\star}$ (Mb/s)	5.72	7.08	8.58	10.41	12.42

They conclude that for moderate throughput demand, conjugate beamforming works best. This is translated in Table V, where, for a required throughput of 6 Mbps, conjugate beamforming delivers the required throughput at a higher efficiency and smaller number of antennas than zero-forcing (40 antennas for cb as opposed to 68 for zf). It should be noted that this is no longer true for higher user throughput since we reach an upper bound for the SINR for conjugate beamforming.

B. Improved Spectral Efficiency

According to [46], the spectral efficiency is the total throughput of all users divided by the bandwidth. It represents how much information can be sent for a given bandwidth, and it is given by the following expression:

$$SE = \frac{C \times T}{B}$$

where C is the coding scheme, T is the throughput, and B is the bandwidth. The spectral efficiency excludes the error correction bits. Therefore, if we wish to increase the spectral efficiency, we need to send as much information as possible inside a given bandwidth. Since MIMO leverages space division multiple access, it is the perfect candidate here [47]. However, using MIMO comes at the cost of increased CCI (co-channel interference) [48]. Luckily, this can be solved with beamforming, as sending the signal in a selected direction will make sure that users that lie outside the the beam will not register any interference. As a result, beamforming, in a way, allows us to tap into the full potential of MIMO systems in regard to the spectral efficiency.

C. Increased Security

The use of beamforming increases the system's security, as it becomes more difficult for an eavesdropper to intercept information sent between the base station and user equipment. [49] calculates the probability of an eavesdropper (called Eve) to be able to intercept the information. They start by defining the system model to contain a certain number of users and a certain number of antennas distributed among multiple remote radio heads (RRHs) (shown in Fig. 31). We are successful in protecting the information sent to

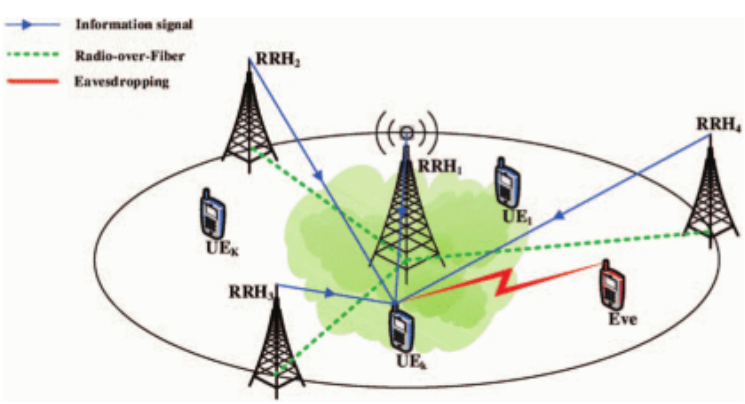

Fig. 31: System under study. Shows users, RRHs and Eve

a user if the received SINR by the user is high, and the SINR registered by Eve is low. To provide a

fair analysis, we will only look at the case where C=1 RRH. The authors obtain the results shown in Fig. 32.

We can see that for C=1, the stated requirements are achieved. Results for C=4 and C=6 are shown for the sake of curiosity. We see that the technique developed by the authors performs even better than beamforming alone, and it would be pretty interesting to apply.

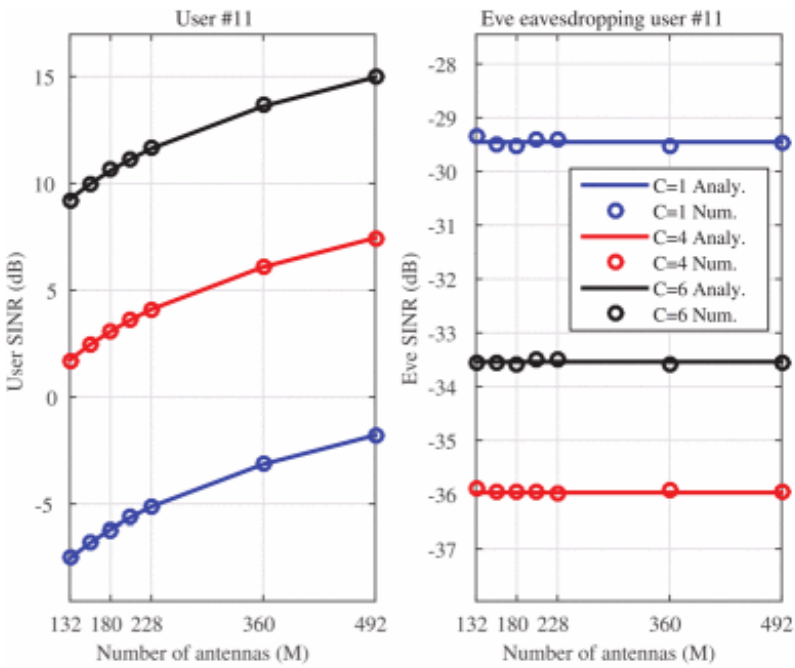

Fig. 32: SINR comparison between UE and Eve

XII. Classification of Beamforming Techniques

Beamforming can be applied in many different methods. Changes in the circuitry, used algorithms, and beam management can significantly alter the performance of beamforming, each by adding some strengths and weaknesses to the system. We will analyze two different classes of techniques: The circuitry and the beam calculation and management. We will discuss analog vs. digital vs. hybrid beamforming, and also switched vs. adaptive beamforming.

A. Analog vs. Digital vs. Hybrid

1) Analog Beamforming: Analog beamforming is probably the simplest among these techniques, and it has existed for many years now. This type of beamforming utilizes phase shifters and is done in RF (Radio Frequency). [50] shows that we can improve cost, reliability and size if we use phased arrays. A

phased array is a collection of antennas, each of which transmits a signal subject to a different phase shift. We show in Fig. 33 an analog transmitter focusing the power in a given direction. We see that for

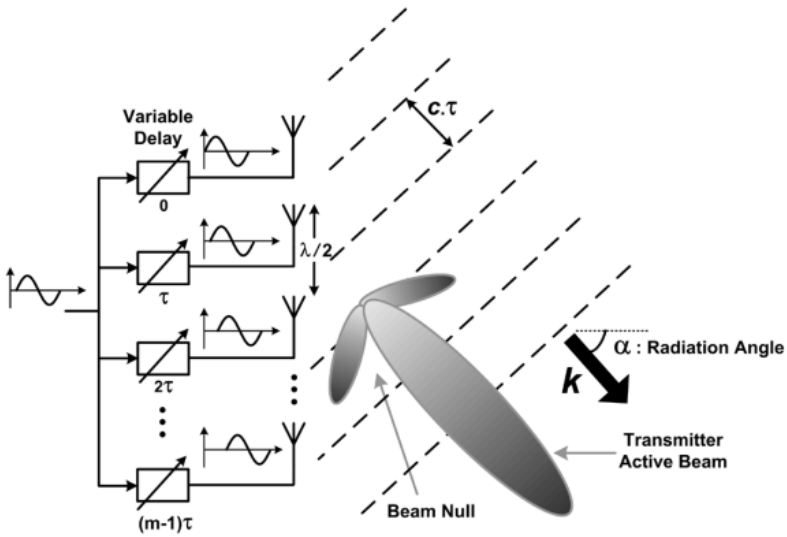

Fig. 33: Analog beamformer at transmitter focusing a beam at a particular angle

a particular calculated set of phase shifts, we can transmit signals from the antennas in such a way that they superpose constructively in the required direction, while giving nulls in almost all other orientations.

However, [51] argues that the previously mentioned design provides no amplitude variation and that the 4-bit phase resolution mentioned in the paper is not sufficient on its own. As a result, analog beamforming is best applied where the cost matters more than pinpoint accuracy.

2) Digital Beamforming: Digital beamforming may be regarded as the opposite of analog beamforming. The processing is done in the baseband rather than RF, it provides high beam control, and it is more expensive and costly. We can see in [52] why digital beamforming is so expensive, and why it is so accurate. As shown in Fig. 34, every antenna in this digital beamforming receiver is connected to a RF translator, and ADC, and a DDC before processing. The RF translator converts the received signal from RF to an IF (Intermediate Frequency). Then the ADC converts this analog signal into a digital one. However, the obtained signal is still in IF, so we need a Digital Down-Converter to convert to baseband, where all the processing can be made. We can easily see how expensive such a system becomes with an increasing number of antennas, but the reward is full control of the signal in the baseband. Therefore, digital beamforming provides the best accuracy, but it quickly becomes infeasible in massive MIMO.

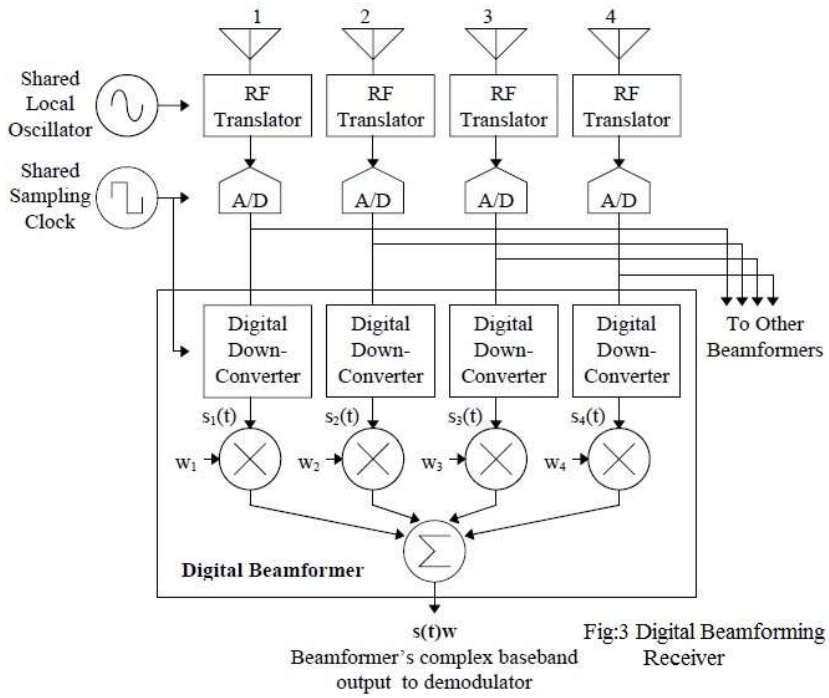

Fig. 34: Digital beamforming receiver architecture

3) Hybrid Beamforming: We have seen that analog beamforming is generally inexpensive but inaccurate, and that digital beamforming provides great flexibility at the expense of increased cost, so an important question automatically arises: Is there a way to find a middle ground between these two techniques? Fortunately, the answer is yes, and it comes in the form of hybrid beamforming. Hybrid beamforming uses digital precoding in the baseband and RF chains (analog) to reduce the number of ADCs. This allows us to maintain a good performance while cutting down on the costs.

[53] provides an example of an implementation of hybrid beamforming (HBF). To understand HBF better, it is helpful to study the signal model given by the following equation:

$$\boldsymbol{y}(k) = \boldsymbol{V}^T \boldsymbol{H}(k) \boldsymbol{W} \boldsymbol{P}(k) \boldsymbol{s}(k) + \boldsymbol{V}^T \boldsymbol{n}(k)$$

We can see from the equation that at the transmitter, for the kth subcarrier (assuming OFDM), the signal $\boldsymbol{s}(k)$ is multiplied by a digital precoding matrix $\boldsymbol{P}(k)$ then by an analog beamforming matrix $\boldsymbol{W}$. This is where the explanation of having both a digital and an analog beamformer comes from (check Fig. 35). As a result, we are able to obtain a beam flexibility which is similar to digital beamforming, while utilizing analog beamforming to render our system less expensive.

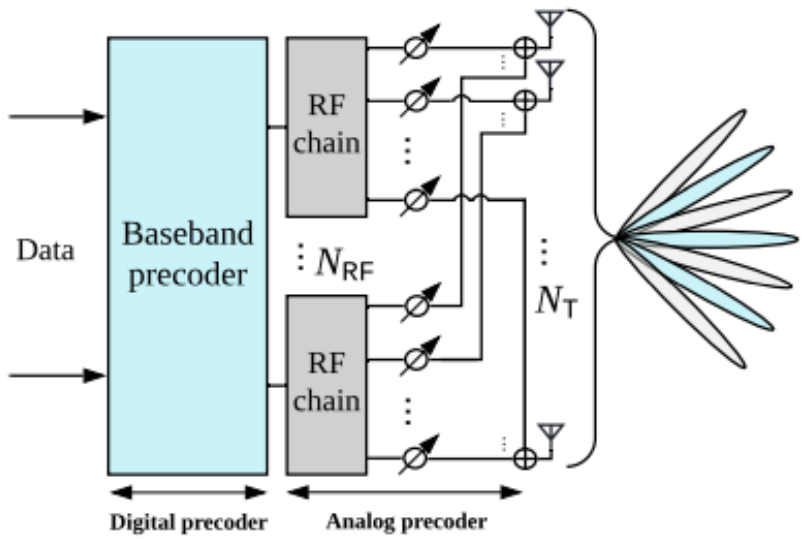

Fig. 35: Hybrid beamforming architecture

B. Switched vs. Adaptive

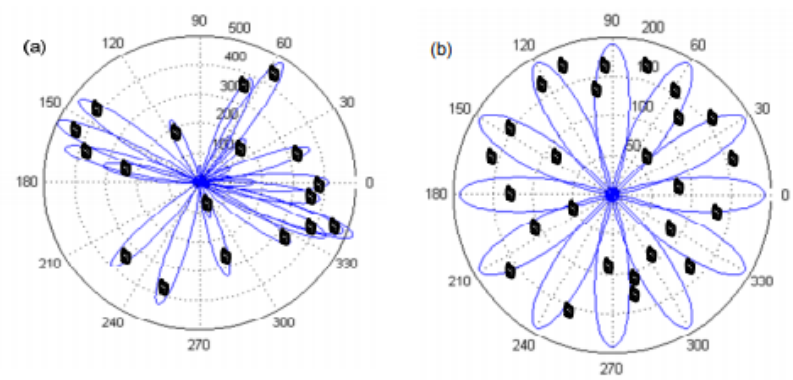

Fig. 36: Adaptive (a) vs. switched (b) beamforming

1) Switched Beamforming: In switched beamforming, there exists a fixed, predefined set of beams that are distributed throughout the area of interest. Since the beams are already calculated, what is left is to simply choose which beam to use to serve a particular user. This renders this choice of beamforming simple and inexpensive. The Butler matrix can be used to perform this switching [54]. However, if we take a look at Fig. 36(b), we see that we might not have a dedicated beam for some users (e.g. near 110°). Also, we might have a beam that serves multiple users (e.g. near 210°), which introduces interference.

2) Adaptive Beamforming: The problems mentioned in switched beamforming can be solved by using adaptive beamforming. In adaptive beamforming, a dedicated beam is calculated for every user (Fig. 36(a)), eliminating the chance of the existence of an unserved user and reducing the amount of interference.

Furthermore, since the beams are tailored for each user, we can make them narrower. This results in an increased coverage area compared to switched beamforming, assuming the use of the same power level. The increased accuracy, on the other hand, comes at the expense of increased complexity and cost. This introduces a trade-off between using the simpler switched beamforming and the more accurate adaptive beamforming.

XIII. Sample Beam Management Algorithm

In this section, we will explore a simple beam management algorithm and introduce a few of the diverse methods that utilize a variety of tools. We discussed in class that we can achieve beamforming in a MIMO system by using SVD decomposition if we know the Channel State Information at the Transmitter (CSI-T). We also discussed that beamforming with SVD is infeasible in real life due to the high complexity associated with the calculation of the SVD and the acquisition of CSIT. As a result, we turn our attention to other possible algorithms to achieve beamforming. We provide a brief summary of one such algorithm, and we mention a few other methods that are still in the domain of research.

[55] explains a simple beam management algorithm. Beam management in New Radio is defined as ”the acquisition and maintenance of a set of transmit and receive beams at both the base station and the UE for both uplink and downlink”, meaning that beams are calculated at the transmitter to ensure that the signal is directed towards the receiver, then the receiver creates a beam which is oriented towards the direction of the transmitted beam. This process is performed in a hierarchical manner which is clearly explained in Fig. 37. The first step consists of sweeping a large beam in search of the receiver. This is know as Initial Base Station Beam Acquisition. When the best beam is found, the second step is Beam Refinement, where narrow beams belonging to the previously found best beam are swept to find the optimal one. Finally, once we choose the transmitter beam, it remains fixed while we perform beam refinement at the UE.

The above algorithm is one way of calculating beams, but it is far from the only one. Beam selection is a prominent field in today’s research, and a vast variety of new algorithms are continuously being explored. Codebooks, which are sets of predefined beamforming matrices, can be used to decrease the overhead of sharing CSI between the transmitter and receiver. Since the codebook can be known at both sides, it is enough to send the index of the best matrix in the codebook instead of sending the

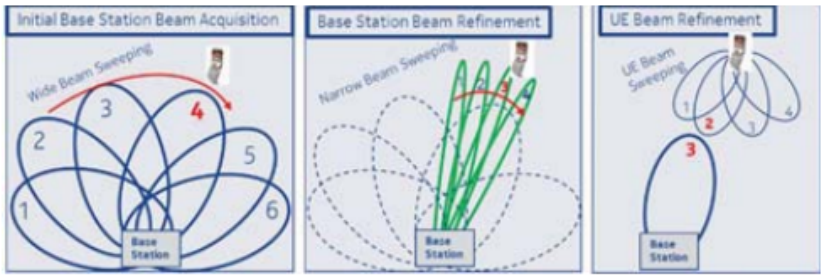

Fig. 37: Sample beam management algorithm using beam sweeping

entire matrix as would be usually done. [56] uses deep learning to construct a codebook based on the received signal strength indicator (RSSI). Furthermore, [57] leverages vision to gain extra information about the environment which helps in the calculation of beams, and it also introduces beam tracking, which predicts future beams using previous ones. With all the novel ideas that are surfacing, it is no doubt that new methods will arise which will make beamforming even more efficient.

XIV. Conclusion

In this report, we explored different aspects of 5G. We presented the different requirements that must be achieved in this new generation, and we explained how these requirements are achieved. We talked about the different types of RAN and the deployment of 5G. We summarized how URLLC conditions are met, and we depicted the structure of the packet and frame to achieve low latency. Moreover, we introduced the concept of numerologies and radio resource allocation in 5G NR, and we resolved some challenges that come with the inception of these numerologies. Furthermore, we explored the physical layer, especially the use of massive MIMO and how they influence the overall efficiency of the system. We have also taken a look at a technology (D2D) that will limit the load in the terminals as the number of users will increase as the years go by. Finally, we tackled the emerging concept of beamforming and presented its benefits. We explained the different methods by which beamforming is achieved, and we concluded with a brief explanation of possible beam management algorithms.

REFERENCES

[1] M. A. Habibi, M. Nasimi, B. Han, and H. D. Schotten, "A comprehensive survey of ran architectures toward 5g mobile communication system," *IEEE Access*, vol. 7, pp. 70 371–70 421, 2019.

[2] L. Gavrilovska, V. Rakovic, and D. Denkovski, "From cloud ran to open ran," *Wireless Personal Communications*, pp. 1–17, 2020.

[3] D. Kim and M. Zarri, "Road to 5g: Introduction and migration," *White Paper*, 2018.

[4] H. Ji, S. Park, J. Yeo, Y. Kim, J. Lee, and B. Shim, "Ultra-reliable and low-latency communications in 5g downlink: Physical layer aspects," *IEEE Wireless Communications*, vol. 25, no. 3, pp. 124–130, 2018.

[5] A. Benjebbour, K. Saito, A. Li, Y. Kishiyama, and T. Nakamura, "Non-orthogonal multiple access (noma): Concept, performance evaluation and experimental trials," in *2015 international conference on wireless networks and mobile communications (WINCOM)*. IEEE, 2015, pp. 1–6.

[6] A. A. Zaidi, R. Baldemair, V. Molés-Cases, N. He, K. Werner, and A. Cedergren, "Ofdm numerology design for 5g new radio to support iot, embb, and mbsfn," *IEEE Communications Standards Magazine*, vol. 2, no. 2, pp. 78–83, 2018.

[7] M. Ibrahim and W. Xu, "On numerology and capacity of the self-contained frame structure," in *2016 IEEE Globecom Workshops (GC Wkshps)*. IEEE, 2016, pp. 1–6.

[8] A. F. Demir and H. Arslan, "Inter-numerology interference management with adaptive guards: A cross-layer approach," *IEEE Access*, vol. 8, pp. 30 378–30 386, 2020.

[9] 3GPP, "3GPP TS 38.101-1 V17.0.0, 3rd Generation Partnership Project; Technical Specification Group Radio Access Network; NR; User Equipment (UE) radio transmission and reception; Part 1: Range 1 Standalone (Release 17)," https://portal.3gpp.org/desktopmodules/Specifications/SpecificationDetails.aspx?specificationId=3283, [Accessed: April 24, 2021].

[10] E. Ali, M. Ismail, R. Nordin, and N. F. Abdulah, "Beamforming techniques for massive mimo systems in 5g: overview, classification, and trends for future research," *Frontiers of Information Technology Electronic Engineering*, vol. 18, no. 6, pp. 753–772, 2017. [Online]. Available: https://doi.org/10.1631/FITEE.1601817

[11] S. J. . N. S, "A review on resource allocation techniques in d2d communication for 5g and b5g technology," *Springer Nature 2020*, pp. 1–13, 2020.

[12] J. Feng, C.-W. Chang, S. Sayilir, Y.-H. Lu, B. Jung, D. Peroulis, and Y. C. Hu, "Energy-efficient transmission for beamforming in wireless sensor networks," in *2010 7th Annual IEEE Communications Society Conference on Sensor, Mesh and Ad Hoc Communications and Networks (SECON)*, 2010, pp. 1–9.

[13] E. T. . . V15.0.0, "Physical layer; General description (3GPP TS 38.201 version 15.0.0 Release 15)," https://www.etsi.org/deliver/etsi_ts/138200_138299/138201/15.00.00_60/ts_138201v150000p.pdf, 2018, [Accessed: April 24, 2021].

[14] A. Yazar and H. Arslan, "A flexibility metric and optimization methods for mixed numerologies in 5g and beyond," *IEEE Access*, vol. 6, pp. 3755–3764, 2018.

[15] P. Schulz, M. Matthe, H. Klessig, M. Simsek, G. Fettweis, J. Ansari, S. A. Ashraf, B. Almeroth, J. Voigt, I. Riedel *et al.*, "Latency critical iot applications in 5g: Perspective on the design of radio interface and network architecture," *IEEE Communications Magazine*, vol. 55, no. 2, pp. 70–78, 2017.

[16] M. Maier, M. Chowdhury, B. P. Rimal, and D. P. Van, "The tactile internet: vision, recent progress, and open challenges," *IEEE Communications Magazine*, vol. 54, no. 5, pp. 138–145, 2016.

[17] C. Bockelmann, N. Pratas, H. Nikopour, K. Au, T. Svensson, C. Stefanovic, P. Popovski, and A. Dekorsy, "Massive machine-type communications in 5g: Physical and mac-layer solutions," *IEEE Communications Magazine*, vol. 54, no. 9, pp. 59–65, 2016.

[18] G. Kardaras and C. Lanzani, "Advanced multimode radio for wireless & mobile broadband communication," in *2009 European Wireless Technology Conference*. IEEE, 2009, pp. 132–135.

[19] J. K. Chaudhary, J. Zou, and G. Fettweis, "Cost saving analysis in capacity-constrained c-ran fronthaul," in *2018 IEEE Globecom Workshops (GC Wkshps)*. IEEE, 2018, pp. 1–7.

[20] O. Arouk, T. Turletti, N. Nikaein, and K. Obraczka, "Cost optimization of cloud-ran planning and provisioning for 5g networks," in *2018 IEEE International Conference on Communications (ICC)*. IEEE, 2018, pp. 1–6.

[21] S. E. Ghoreishi, D. Karamshuk, V. Friderikos, N. Sastry, M. Dohler, and A. H. Aghvami, "A cost-driven approach to caching-as-a-service in cloud-based 5g mobile networks," *IEEE Transactions on Mobile Computing*, vol. 19, no. 5, pp. 997–1009, 2019.

[22] J. Rendon Schneir, A. Ajibulu, K. Konstantinou, J. Bradford, G. Zimmermann, H. Droste, R. Canto *et al.*, "A business case for 5g mobile broadband in a dense urban area," *Telecommunications Policy*, vol. 43, no. 7, pp. 1–1, 2019.

[23] B. Dzogovic, B. Feng, T. Van Do *et al.*, "Building virtualized 5g networks using open source software," in *2018 IEEE Symposium on Computer Applications & Industrial Electronics (ISCAIE)*. IEEE, 2018, pp. 360–366.

[24] H.-C. Chang, B.-J. Qiu, C.-H. Chiu, J.-C. Chen, F. J. Lin, D. De La Bastida, and B.-S. P. Lin, "Performance evaluation of open5gcore over kvm and docker by using open5gmtc," in *NOMS 2018-2018 IEEE/IFIP Network Operations and Management Symposium*. IEEE, 2018, pp. 1–6.

[25] "Study on scenarios and requirements for next generation access technologies (release 14)," *3GPP Tech*, 2017.

[26] N. A. Johansson, Y.-P. E. Wang, E. Eriksson, and M. Hessler, "Radio access for ultra-reliable and low-latency 5g communications," in *2015 IEEE International Conference on Communication Workshop (ICCW)*. IEEE, 2015, pp. 1184–1189.

[27] M. Sybis, K. Wesolowski, K. Jayasinghe, V. Venkatasubramanian, and V. Vukadinovic, "Channel coding for ultra-reliable low-latency communication in 5g systems," in *2016 IEEE 84th vehicular technology conference (VTC-Fall)*. IEEE, 2016, pp. 1–5.

[28] "Technical specification group radio access network, nr (release 15)," *3GPP Tech. Spec. 38.211*, v15.0.0, 2017.

[29] H. Ji, S. Park, and B. Shim, "Sparse vector coding for ultra reliable and low latency communications," *IEEE Transactions on Wireless Communications*, vol. 17, no. 10, pp. 6693–6706, 2018.

[30] J. W. Choi, B. Shim, Y. Ding, B. Rao, and D. I. Kim, "Compressed sensing for wireless communications: Useful tips and tricks," *IEEE Communications Surveys & Tutorials*, vol. 19, no. 3, pp. 1527–1550, 2017.

[31] Y. Kishiyama, A. Benjebbour, H. Ishii, and T. Nakamura, "Evolution concept and candidate technologies for future steps of lte-a," in *2012 IEEE International Conference on Communication Systems (ICCS)*. IEEE, 2012, pp. 473–477.

[32] "Evolved universal terrestrial radio access (e-utra) and evolved universal terrestrial radio access network (e-utran)."

[33] "Further advancements for e-utra physical layer aspects," Mar. 2010.

[34] E. T. . . V16.1.0, "5G NR; Medium Access Control (MAC) protocol specification (3GPP TS 38.321 version 16.1.0 Release 16)," https://www.etsi.org/deliver/etsi_ts/138300_138399/138321/16.01.00_60/ts_138321v160100p.pdf, 2020, [Accessed: April 24, 2021].

[35] E. T. . . V15.2.0, "Physical channels and modulation (3GPP TS 38.211 version 15.2.0 Release 15)," https://www.etsi.org/deliver/etsi_ts/138200_138299/138211/15.02.00_60/ts_138211v150200p.pdf, 2018, [Accessed: April 24, 2021].

[36] D. Wu and R. Negi, "Effective capacity: a wireless link model for support of quality of service," *IEEE Transactions on wireless communications*, vol. 2, no. 4, pp. 630–643, 2003.

[37] X. Zhang, L. Zhang, P. Xiao, D. Ma, J. Wei, and Y. Xin, "Mixed numerologies interference analysis and inter-numerology interference cancellation for windowed ofdm systems," *IEEE Transactions on Vehicular Technology*, vol. 67, no. 8, pp. 7047–7061, 2018.

[38] J. Choi, B. Kim, K. Lee, and D. Hong, "A transceiver design for spectrum sharing in mixed numerology environments," *IEEE Transactions on Wireless Communications*, vol. 18, no. 5, pp. 2707–2721, 2019.

[39] X. Cheng, R. Zayani, H. Shaiek, and D. Roviras, "Inter-numerology interference analysis and cancellation for massive mimo-ofdm downlink systems," *IEEE Access*, vol. 7, pp. 177 164–177 176, 2019.

[40] J. Mao, L. Zhang, P. Xiao, and K. Nikitopoulos, "Interference analysis and power allocation in the presence of mixed numerologies," *IEEE Transactions on Wireless Communications*, vol. 19, no. 8, pp. 5188–5203, 2020.

[41] M. Yang, Y. Chen, Y. Liu, L. Du, and Z. Liu, "Cp optimization for multi-numerologies f-ofdm in mimo system," in *2019 28th Wireless and Optical Communications Conference (WOCC)*. IEEE, 2019, pp. 1–5.

[42] E. Memisoglu, A. B. Kihero, E. Basar, and H. Arslan, "Guard band reduction for 5g and beyond multiple numerologies," *IEEE Communications Letters*, vol. 24, no. 3, pp. 644–647, 2019.

[43] E. Nam, T. Kim, J. Park, and K. Bae, "Outage probability-based adaptive guard band allocation for mixed numerology," in *2020 IEEE 17th Annual Consumer Communications & Networking Conference (CCNC)*. IEEE, 2020, pp. 1–4.

[44] T. T. Nguyen, V. N. Ha, and L. B. Le, "Wireless scheduling for heterogeneous services with mixed numerology in 5g wireless networks," *IEEE Communications Letters*, vol. 24, no. 2, pp. 410–413, 2019.

[45] H. Yang and T. L. Marzetta, "Energy efficient design of massive mimo: How many antennas?" in *2015 IEEE 81st Vehicular Technology Conference (VTC Spring)*, 2015, pp. 1–5.

[46] K. S. Mohamed, M. Y. Alias, and M. Roslee, "Power spectral density and spectral efficiency analysis in line-of-sight 2.6 ghz beamforming femtocell networks," in *2019 IEEE 14th Malaysia International Conference on Communication (MICC)*, 2019, pp. 130–135.

[47] E. Björnson, "How much does massive mimo improve the spectral efficiency?" Oct 2016. [Online]. Available: https://ma-mimo.ellintech.se/2016/10/18/how-much-does-massive-mimo-improve-spectral-efficiency/#:~:text=A%20great%20way%20to%20improve,can%20improve%20the%20spectral%20efficiency.

[48] A. Faisal, F. Hashim, N. Noordin, M. Ismail, and A. Jamalipour, "Efficient beamforming and spectral efficiency maximization in a joint transmission system using an adaptive particle swarm optimization algorithm," *Applied Soft Computing*, vol. 49, pp. 759–769, 2016. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1568494616304689

[49] K. Guo, Y. Guo, and G. Ascheid, "Distributed antennas aided secure communication in mu-massive-mimo with qos guarantee," in *2015 IEEE 82nd Vehicular Technology Conference (VTC2015-Fall)*, 2015, pp. 1–7.

[50] A. Hajimiri, H. Hashemi, A. Natarajan, X. Guan, and A. Komijani, "Integrated phased array systems in silicon," *Proceedings of the IEEE*, vol. 93, no. 9, pp. 1637–1655, 2005.

[51] V. Venkateswaran and A.-J. van der Veen, "Analog beamforming in mimo communications with phase shift networks and online channel estimation," *IEEE Transactions on Signal Processing*, vol. 58, no. 8, pp. 4131–4143, 2010.

[52] "Analog beamforming vs digital beamforming — difference between analog beamforming and digital beamforming." [Online]. Available: https://www.rfwireless-world.com/Terminology/Analog-Beamforming-vs-Digital-Beamforming.html

[53] C. Kim, T. Kim, and J.-Y. Seol, "Multi-beam transmission diversity with hybrid beamforming for mimo-ofdm systems," in *2013 IEEE Globecom Workshops (GC Wkshps)*, 2013, pp. 61–65.

[54] H. Ren, B. Arigong, M. Zhou, J. Ding, and H. Zhang, "A novel design of 4×4 butler matrix with relatively flexible phase differences," *IEEE Antennas and Wireless Propagation Letters*, vol. 15, pp. 1277–1280, 2016.

[55] F. W. Vook, A. Ghosh, E. Diarte, and M. Murphy, "5g new radio: Overview and performance," in *2018 52nd Asilomar Conference on Signals, Systems, and Computers*, 2018, pp. 1247–1251.

[56] H. Hojatian, J. Nadal, J.-F. Frigon, and F. Leduc-Primeau, "Unsupervised deep learning for massive mimo hybrid beamforming," 2020.

[57] M. Alrabeiah, J. Booth, A. Hredzak, and A. Alkhateeb, "Viwi vision-aided mmwave beam tracking: Dataset, task, and baseline solutions," 2020.